

Модель отрицательного биномиального распределения в анализе категориальных последовательностей

Григорян Юрий Каренович, гр. 22.Б04-мм

Научный руководитель: кандидат физико-математических наук,
доцент Алексеева Нина Петровна

Рецензент: специалист ФГБУ «НМИЦ ПН им. В.М.Бехтерева»
Скурат Евгения Петровна

Санкт-Петербургский государственный университет
Прикладная математика, программирование и искусственный интеллект
Кафедра статистического моделирования

Санкт-Петербург
2026 г.

Изучается случайная величина

X_i = число появлений фиксированного события в i -м блоке длины L .

Почему рассматривается ОБР

Отрицательное биномиальное распределение возникает не только как классическая схема испытаний Бернулли, но и как результат более сложных случайных механизмов:

Гамма–пуассоновская смесь, Сложное распределение Пуассона с лог. слагаемыми.

Известный контекст

- в работах А.Г.Барта ОБР рассматривалась как модель, связанная со сложным распределением Пуассона;
- в работах Н. П. Алексеевой и соавторов ОБР применялась для описания встречаемости слов в текстах;

Переход в работе

- в финансовом ряду готового аналога слова нет;
- вводится алфавит состояний цены;
- событие задаётся как появление паттерна фиксированной длины.

Идея работы — проверить ОБР-подход на финансовых паттернах.

Цель: исследовать применимость отрицательного биномиального распределения к блочным частотам финансовых паттернов и выявить структуру параметров модели.

Задачи:

- 1 описать лингвистический этап как исходную схему анализа частот;
- 2 построить финансовые паттерны на основе алфавита изменения ценовых состояний;
- 3 оценить параметры ОБР и проверить гипотезу согласия;
- 4 исследовать расположение оценок (r, p) в параметрическом пространстве;
- 5 объяснить наблюдаемую структуру через среднюю интенсивность μ ;
- 6 проанализировать интервалы между появлениями паттернов.

Ключевой вопрос

Если финансовый паттерн согласуется с ОБР, возникает ли устойчивая структура его параметров (r, p) ?

X = число появлений фиксированного элемента в блоке длины L

$$P\{X = k\} = \frac{\Gamma(k+r)}{\Gamma(k+1)\Gamma(r)} p^r (1-p)^k, \quad k = 0, 1, 2, \dots$$
$$r > 0, \quad 0 < p < 1$$

Среднее и дисперсия:

$$\mu = \mathbb{E}X = \frac{r(1-p)}{p}$$

$$\mathbb{D}X = \frac{r(1-p)}{p^2} = \frac{\mu}{p} > \mu$$

ОБР позволяет описывать счётные данные с повышенной изменчивостью частот по блокам.

Проверка согласия: $H_0: X \sim NB(\hat{r}, \hat{p})$, критерий χ^2 Пирсона, $\alpha = 0.05$, $df = m - 3$ (m — число групп после объединения, 2 оценённых параметра).

Связь параметров:

$$r = \mu \frac{p}{1-p}$$

Если для группы элементов средняя интенсивность μ близка к постоянной, то точки (r, p) должны располагаться вдоль гладкой кривой.

Данные: роман «Братья Карамазовы», разбиение на $n = 70, 80, \dots, 150$ блоков.

Не Отвергнуто H_0 (Модель согласована):

- служебные слова: «и», «в», «не»
- общеупотребительные: «было», «как»

Нейтральная лексика распределена по тексту равномерно в рамках модели.

Отвергнуто H_0 :


- имена персонажей: «Алёша», «Митя»
- сюжетно значимые слова

Появляются «кучно» — связаны с конкретными эпизодами.

Эффект Алёши

Для слова «Алёша» H_0 отвергается при всех вариантах разбиения ($p\text{-value} < 0.05$). Для таких слов согласована модель **ZINB** (Zero-Inflated NB) — обобщение ОБР, учитывающее избыток нулей.

Результат: ОБР выступает «нулевой моделью»: отклонение от неё — **индикатор содержательной значимости** элемента последовательности.



Пояснение к графику: горизонтальная ось — параметр r , вертикальная — параметр p ; каждая точка — одно слово при разбиении на 80 блоков.

Наблюдения по лингвистическому этапу:

- нейтральная лексика образует компактное облако в пространстве (r, p) ;
- сюжетно значимые слова выделяются на общем фоне;
- структура сохраняется при смене числа блоков.

В следующем этапе эта идея о параметрическом пространстве как инструменте анализа переносится на финансовые данные.

В лингвистике:

- элементы последовательности заданы естественно;
- слово отделяется пробелами;
- анализируется частота уже существующих лексем.

В финансовом ряду:

- готового аналога «слова» нет;
- сначала вводится алфавит состояний;
- затем строятся все паттерны фиксированной длины.

$$W_t = (C_t, C_{t+1}, C_{t+2})$$

$4^3 = 64$ возможных паттерна

Категоризация ценового ряда:

$$C_t = \begin{cases} \text{СР}, & \Delta P_t > \sigma \\ \text{Р}, & 0 < \Delta P_t \leq \sigma \\ \text{П}, & -\sigma \leq \Delta P_t < 0 \\ \text{СП}, & \Delta P_t < -\sigma \end{cases}$$

σ — стандартное отклонение дневных изменений актива.

Данные:

- 14 компаний, 4 сектора;
- 112 пар «бренд–паттерн»;
- 8 наиболее частых паттернов на компанию;
- размеры блоков: $L = 80, 90, 100$.

Строки — размер блока L ; столбцы — исходы

теста.	L	Не отв. H_0	Отв. H_0	Доля
	80	31	81	27.7%
	90	29	83	25.9%
	100	27	85	24.1%

Доля показывает, для какой части искусственно построенных финансовых паттернов ОБР не отвергается.

Секторальные различия

доля отвержения, $L = 80$


Сектор	Отвергнуто
Consumer	71.9%
Finance	75.0%
Retail	71.9%
Tech	71.9%

По доле отвержения сектора близки. Поэтому далее анализируется не только факт принятия или отвержения H_0 , но и расположение оценок (r, p) в параметрическом пространстве.

Отдельное наблюдение

Паттерн [П, П, П] часто согласуется с ОБР, тогда как паттерны роста чаще отвергаются. Это указывает на различие в структуре появления паттернов падения и роста.


Параметрическое пространство финансовых паттернов, $L = 80$




Пояснение к графику:

- горизонтальная ось — $\hat{r}$, вертикальная — $\hat{p}$;
- пунктир — теоретическая кривая $r = \bar{\mu} \cdot p / (1 - p)$.

Параметрическое пространство финансовых паттернов, $L = 90$



Параметрическое пространство финансовых паттернов, $L = 100$



Сравнение масштабов:

- при $L = 90$ дуга сохраняется, но сжимается вдоль оси r ;
- при $L = 100$ происходит дальнейшее сжатие и смещение точек;
- относительная структура параметрического пространства сохраняется.

Вывод: геометрическая структура сохраняется при изменении L , хотя её положение и масштаб меняются.

Из формулы среднего:

$$\mu = \frac{r(1-p)}{p} \implies \boxed{r = \bar{\mu} \cdot \frac{p}{1-p}} \quad \text{— уравнение наблюдаемой дуги.}$$

Строки таблицы — размер блока; столбцы — статистики μ по принятым паттернам.

L	N	$\bar{\mu}$	σ_{μ}	CV	H (KW)	p -value
80	31	7.20	0.97	0.135	11.53	0.073
90	29	8.12	1.01	0.124	9.21	0.056
100	27	9.12	1.13	0.124	10.36	0.110

$CV \leq 13.5\%$ — μ меняется слабо при фиксированном L .

Критерий Краскела–Уоллиса: H_0 об однородности μ **не отвергается** при всех L ($p > 0.05$).

Результат: Дуга — не визуальный артефакт, а следствие **приближённого постоянства средней интенсивности μ** для устойчивых паттернов.


Постановка: для паттерна, появляющегося в позициях $t_1 < t_2 < \dots < t_m$, рассматриваются интервалы $\tau_i = t_{i+1} - t_i$.

Строки — статус паттерна по ОБР; столбцы — характеристики интервалов.


Показатель	НВ отвергнута	НВ принята
Число паттернов	81	31
Средний CV	1.63	1.62
$P(\tau = 1)$	0.05	0.27
$P(\tau \leq 3)$	0.21	0.38
Средний интервал	10.4	11.1

Результат: принятые паттерны чаще появляются **короткими сериями** ($\tau = 1$ в 27% случаев против 5%). Стандартные модели интервалов (экспоненциальное, гамма, Вейбулл) не согласованы ни для одного паттерна.

Гистограмма интервалов: Apple, паттерн [П,П,П]



Гистограмма интервалов: NVIDIA, паттерн [P,П,P]



Мною получены следующие результаты:

- 1 **Лингвистика:** ОБР является «нулевой моделью» для текста; отклонение от неё — индикатор сюжетной значимости слова; для аномальных слов согласована модель ZINB.
- 2 **Финансы:** ОБР применима для 27.7% паттернов ($L = 80$); паттерны падения статистически устойчивее паттернов роста; секторальные различия проявляются в структуре параметрического пространства, а не в доле отвержений.
- 3 **Геометрическая инвариантность:** оценки (r, p) принятых паттернов располагаются вдоль выпуклой дуги, устойчивой при $L = 80, 90, 100$.
- 4 **Объяснение дуги:** $r = \bar{\mu} \cdot p / (1 - p)$; средняя интенсивность μ приближённо постоянна для устойчивых паттернов ($CV \leq 13.5\%$), подтверждено критерием Краскела–Уоллиса.
- 5 **Интервалы:** принятые паттерны чаще образуют короткие серии ($P(\tau = 1) = 27\%$ против 5%); стандартные модели интервалов не согласованы.

Спасибо за внимание!