

Дисперсионный анализ для повторных измерений в условиях неполных данных

Запороженко Мария Александровна, 22.Б04-мм группа

Кафедра статистического моделирования
Математико-механический факультет
Санкт-Петербургский государственный университет

Научный руководитель: к. ф.-м. н., доцент Н. П. Алексеева

Рецензент: Специалист, Общество с ограниченной ответственностью «АЙТИ Компас»
Р. А. Леонович

Санкт-Петербург
2026 г.

Области применения

- Биомедицинские исследования (клинические испытания).
- Экономика (панельные данные).
- Социология (опросы во времени).

Основной инструмент в работе с лонгитюдными данными

RM-ANOVA (Repeated Measures Analysis of Variance) — дисперсионный анализ повторных измерений.

Механизмы пропусков данных

- MCAR (Missing Completely At Random)
- MAR (Missing At Random)
- MNAR (Missing Not At Random)

Недостатки традиционных подходов

Метод	Суть	Недостатки
Listwise Deletion	Удаление всех с пропусками	Потеря мощности, смещение
Imputation	Замена средним / последним	Занижение дисперсии, риск ошибок I рода
FIML / REML	Прямая оценка параметров модели по функции правдоподобия	Требуется предположения о MAR; вычислительно сложно; чувствительность к спецификации модели

Вывод

Необходим метод, устойчивый к пропускам **без восстановления значений** и жесткой чувствительности к спецификации модели.

Цель: Исследование теоретического обоснования сходимости алгоритма индивидуальной коррекции в методе двойственной балансировки, разработка нового ограничения на пропуски и программная реализация метода и многофакторного обобщения.

Задачи

- 1 Теоретическое обоснование сходимости при ослабленных ограничениях на пропуски.
- 2 Эмпирическое исследование на клинических данных.
- 3 Многофакторное обобщение.
- 4 Симуляционная валидация.

Классическая модель RM-ANOVA

Двухфакторная модель с повторными измерениями

$$x_{ijt} = \mu + \alpha_i + e_{ij}^1 + \beta_t + \gamma_{it} + e_{ijt}$$

- $i = 1 \dots I$ — группа (например, пол).
- $t = 1 \dots T$ — момент времени.
- $j = 1 \dots \nu_i$ — индивид в группе.
- μ — генеральное среднее.
- $\alpha_i, \beta_t, \gamma_{it}$ — фиксированные эффекты.
- e_{ij}^1, e_{ijt} — случайные ошибки ($N(0, \sigma^2)$).

Ограничения

Суммы эффектов равны нулю (взвешенные по количеству наблюдений).

Идея

Компенсация смещения через введение поправок к средним.

Два уровня коррекции

① Групповая коррекция (G)

- Компенсирует неравномерность пропусков *между группами*.
- Выравнивает вклад временных эффектов в групповые средние.

② Индивидуальная коррекция (H_i)

- Компенсирует неравномерность пропусков *во времени* для конкретного индивида.

Для i -й группы определим матрицу $\mathbf{R}_i = \mathbf{\Lambda}_{\nu_i} \mathbf{J}_i$ и стохастическую матрицу переходов $\mathbf{P}_i$ размера $\nu_i \times \nu_i$:

$$\mathbf{P}_i = \mathbf{R}_i \mathbf{\Lambda}_{iT} \mathbf{J}_i^T,$$

где $\mathbf{J}_i$ — матрица инцидентности, $\mathbf{\Lambda}_{\nu_i} = \text{diag}(1/n_{ij})$, $\mathbf{\Lambda}_{iT} = \text{diag}(1/m_{it})$.

Введём векторы временных и индивидуальных средних для i -й группы:

$\mathbf{U}_i = (x_{i \cdot 1}, \dots, x_{i \cdot T})^T$ и $\mathbf{V}_i = (x_{i1 \cdot}, \dots, x_{i\nu_i \cdot})^T$.

Вектор поправок $\mathbf{H}_i$

$$\mathbf{H}_i = \sum_{k=1}^{\infty} \mathbf{A}_i(k), \quad \mathbf{A}_i(k) = \mathbf{P}_i \mathbf{A}_i(k-1), \quad \mathbf{A}_i(0) = \mathbf{R}_i \mathbf{U}_i - \mathbf{P}_i \mathbf{V}_i.$$

Свойства скорректированной модели

Формирование новых переменных

$$z_{ij} = x_{ij.} - H_{ij} - G_i, \quad y_{ijt} = x_{ijt} - z_{ij}$$

Теорема (О несмещённости, Н.П.Алексеевой)

$$\mathbb{E}[z_{ij}] = \mu + \alpha_i, \quad \mathbb{E}[y_{ijt}] = \beta_t + \gamma_{it}$$

Вывод

Поправки полностью устраняют смещение, вызванное структурой пропусков.

Условия сходимости индивидуальной коррекции

Проблема

Сходимость ряда индивидуальной коррекции $\mathbf{H}_i = \sum_{k=1}^{\infty} \mathbf{A}_i(k)$ зависит от эргодических свойств $\mathbf{P}_i$. Требуется существование единственного стационарного распределения.

Определение (Якорный индивид)

Индивид j^* называется якорным, если:

- 1 У него нет пропусков ($n_{ij^*} = T$).
- 2 Все остальные индивиды имеют хотя бы одно наблюдение ($n_{ij} \geq 1$).

Теорема

Наличие якорного индивида гарантирует **единственное стационарное распределение** матрицы $\mathbf{P}_i$.

- *Значение*

Не требуется момент времени со 100% заполнением группы.

Линейная модель: $\mathbf{Y} = \mathbf{H}\boldsymbol{\theta} + \boldsymbol{\varepsilon}$, $\text{Cov}(\boldsymbol{\varepsilon}) = \mathbf{V}$.

Оценка ОМНК: $\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{V}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{V}^{-1} \mathbf{Y}$.

Статистика для проверки гипотезы

$$F = \frac{(Q_{\text{red}} - Q_{\text{full}})/\nu_1}{Q_{\text{full}}/\nu_2} \sim F(\nu_1, \nu_2)$$

Проверяемые гипотезы

- ❶ **Групповой эффект:** $H_0 : \alpha_1 = \dots = \alpha_I = 0$.
- ❷ **Временной эффект:** $H_0 : \beta_1 = \dots = \beta_T = 0$.
- ❸ **Взаимодействие:** $H_0 : \gamma_{it} = 0$.

Источник данных

Клиническое наблюдение, кардиохирургия.

- **Объем выборки:** $N = 165$ пациентов.
- **Зависимая переменная:** Размер левого желудочка (LVd, мм).
- **Факторы:**
 - Пол (2 группы: М/Ж).
 - Время (5 точек: До, После, 3 контроля).

Статистика пропусков

Полный профиль имеют только 48 человек (29%). Потенциальная потеря данных при классическом подходе: **71%**.

Сценарий	Метод	N	Потеря
A	Классический ANOVA (Complete Case)	48	71%
B	Импутация (Заполнение средним)	165	0%
C	Двойственная балансировка (Полное наблюдение)	160	3%
D	Двойственная балансировка (Якорный)	165	0%

- **Сценарий C:** полный охват хотя бы в один момент времени.
- **Сценарий D:** условие якорного индивида.

Результаты проверки гипотез

Уровень значимости $\alpha = 0.05$.

Эффект	A	B	C	D
Группа (Пол)	0.043	0.000	0.000	0.000
Время	0.112	0.000	0.000	0.000
Взаимодействие	0.982	0.408	0.887	0.877

- **A:** Не выявил значимости Времени ($p = 0.11$) из-за малой выборки.
- **D:** Подтвердил значимость Пол и Время ($p < 0.001$).
- **Взаимодействие:** Не значимо $\Rightarrow$ динамика параллельна.

Динамика показателя LVd




Рис.: Динамика показателя LVd в зависимости от пола пациента

Примечание: M — мужской пол, W — женский пол; виден резкий постоперационный спад LVd.

Эффект времени

- Операция приводит к значимому уменьшению размера левого желудочка ($p < 0.001$).
- Классический метод (А) «не увидел» этот эффект ($p = 0.11$) $\Rightarrow$ риск ошибки II рода.

Эффект группы (Пол)

- Систематическое различие абсолютных значений LVd ($p < 0.001$).
- Взаимодействие Пол $\times$ Время незначимо ($p \approx 0.88$).

Клинический вывод

Динамика восстановления **параллельна** у мужчин и женщин.

Условие «якорного индивида» позволило сохранить всю выборку.

Валидация: равномерность распределения p-value

Теоретическое свойство

При верной H_0 $p\text{-value} \sim \text{Uniform}[0,1]$.

Критерий Колмогорова–Смирнова (KS-test):

Метод	Эффект	KS-stat	p_{KS}
AU.2	Group	0.0349	0.575
	Time	0.0458	0.245
	Interaction	0.0390	0.434
ANOVA (CC)	Group	0.0815	0.0048
	Time	0.265	0.0000
	Interaction	0.0640	0.048

AU.2 сохраняет корректное распределение $p\text{-value}$. Complete cases ANOVA нарушает равномерность $\Rightarrow$ тест неприменим.

Идея обобщения: Суперфактор

Пусть имеется K категориальных факторов $F_1, \dots, F_K$ с L_k уровнями.

- Строится **суперфактор** S , объединяющий все $I = \prod L_k$ комбинаций уровней.
- Модель записывается с индексом суперфактора g :

$$x_{gjt} = \mu + \alpha_g + e_{gj}^1 + \beta_t + \gamma_{gt} + e_{gjt}$$

- К модели применяется стандартная процедура двойственной балансировки.

Эмпирический многофакторный анализ

Эффект	F	df	p -value
Суперфактор (все группы)	7.13	3, 159	< 0.001
Время (β)	15.74	4, 336	< 0.001
Суперфактор $\times$ Время	0.67	12, 336	0.792
Пол (Sex)	17.00	1, 159	< 0.001
Возрастная группа (Age)	0.043	1, 159	0.835
Пол $\times$ Возраст	0.534	1, 159	0.466
Пол $\times$ Время	0.233	4, 336	0.920
Возраст $\times$ Время	0.380	4, 336	0.823
Пол $\times$ Возраст $\times$ Время	0.469	4, 336	0.758

Вывод

Основной источник вариабельности — **Пол** и **Время**. Возрастной эффект и все взаимодействия незначимы.

Сходимость алгоритма и границы применимости




Рис.: Карта сходимости метода в зависимости от механизма, паттерна и доли пропусков

Двухфакторная модель с повторными измерениями

$$x_{ijt} = \mu + \alpha_i + e_{ij}^1 + \beta_t + \gamma_{it} + e_{ijt}$$

Параметры для моделирования:

- $I = 2$ группы, $T = 3$ временные точки.
- $\mu = 100$
- $\alpha_1 = -5$, $\alpha_2 = +5$.
- $\beta_1 = 0$, $\beta_2 = +4$, $\beta_3 = +8$.
- $\gamma_{1t} = [0, -2, -4]$, $\gamma_{2t} = [0, +2, +4]$.
- $\sigma^2(e_{ij}^1) = 2$.
- $\sigma^2(e_{ijt}) = 1$.
- 50 испытуемых в каждой группе.

- ❶ Реализован метод двойственной балансировки для RM-ANOVA.
- ❷ **Сформулировано условие «Якорный индивид»:**
 - Менее строгое, чем требование полной временной точки.
 - Гарантирует сходимость алгоритма индивидуальной коррекции.
 - Доказано через свойства конечных цепей Маркова (Феллер).
- ❸ **Получено многофакторное обобщение** через суперфактор.
- ❹ **Валидация**
Граница устойчивости — 90%.
- ❺ **Применимость**
Метод рекомендован для медицинской статистики, экономики и социологии, где пропуски неизбежны.

Доклад окончен

Спасибо за внимание!

Почему возникает смещение?

Выборочное среднее индивида при пропусках

$$x_{ij.} = \frac{1}{n_{ij}} \sum_{t \in N_{ij}} x_{ijt},$$

где N_{ij} — множество моментов времени, в которые получены данные об индивиде i в группе j , $n_{ij} = |N_{ij}|$.

Математическое ожидание

$$\mathbb{E}[x_{ij.}] = \mu + \alpha_i + \underbrace{\frac{1}{n_{ij}} \sum_{t \in N_{ij}} (\beta_t + \gamma_{it})}_{\text{Смещение!}}$$

- **Ограничения модели:** взвешенные суммы эффектов равны 0.
- **В сбалансированном плане:** $\sum_{t=1}^T (\beta_t + \gamma_{it}) = 0$.
- **При пропусках:** $\sum_{t \in N_{ij}} (\beta_t + \gamma_{it}) \neq 0 \Rightarrow$ оценка α_i смещена.

Математический аппарат — Групповая коррекция

Число наблюдений в i -ой группе, в t -ой и во всех точках соответственно равно:

$$m_{i.} = \sum_{t=1}^T m_{it}, \quad m_{.t} = \sum_{i=1}^I m_{it}, \quad m_{..} = \sum_{i=1}^I \sum_{t=1}^T m_{it}.$$

Стохастические матрицы равны $\mathbf{M} = \left(\frac{m_{it}}{m_{i.}} \right)_{I \times T}$, $\mathbf{N} = \left(\frac{m_{it}}{m_{.t}} \right)_{T \times I}$.

Матрица переходов между группами: $\mathbf{P}_0 = \mathbf{M}\mathbf{N}$.

Вектор поправок определяется как $\mathbf{G} = \sum_{k=0}^{\infty} \mathbf{P}_0^k (\mathbf{M}\mathbf{L} - \mathbf{P}_0\mathbf{K})$, где $\mathbf{L} = (x_{..1} - x_{...}, \dots)^T$, $\mathbf{K} = (x_{1..} - x_{...}, \dots)^T$.

Свойство (Н.П.Алексеева)

$\mathbb{E}[\mathbf{G}] = \mathbf{M}\mathbf{b}$. Поправка устраняет смещение групповых средних за счёт временных эффектов.

Интерпретация через граф переходов

- Вершины — индивиды.
- Ребро $(j \rightarrow k)$ существует, если они наблюдались в одно время.

Роль якорного индивида j^*

- 1 Так как j^* наблюдается всегда, из любого j есть путь в j^* .
- 2 Из j^* есть путь в любой k (так как k имеет хоть одно наблюдение).
- 3 **Вывод:** Граф сильно связный $\Rightarrow$ цепь неразложима.

Наличие петли в j^* гарантирует апериодичность.

Неразложимость + Апериодичность $\Rightarrow$ Сходимость (по эргодической теореме Феллера).

Теорема (Феллер)

Неразложимая апериодическая цепь Маркова относится к одному из следующих двух классов:

1 Невозвратные (или нулевые) состояния:

- Все состояния цепи невозвратны либо нулевые.
- В этом случае $\forall i, j \in X$:

$$p_{ij}^{(n)} \xrightarrow{n \rightarrow \infty} 0$$

- Не существует стационарного распределения цепи.

2 Положительные состояния:

- Все состояния цепи положительны.
- В этом случае $\forall i, j \in X$:

$$p_{ij}^{(n)} \xrightarrow{n \rightarrow \infty} p_j > 0$$

- $\{p_j, j \in X\}$ является **стационарным распределением** цепи.
- Не существует других стационарных распределений.

Условие сходимости для конечных цепей Маркова

Утверждение о конечных цепях

Для конечной цепи Маркова с N состояниями выполняется **только пункт (б)** эргодической теоремы Феллера (все состояния положительны).

Доказательство методом от противного.

Пусть существует конечная ЦМ с N состояниями, для которой выполняется пункт (а) теоремы Феллера (все состояния невозвратны или нулевые).

1. **Свойство стохастичности:** для любого шага n и любого состояния i : $\sum_{j=1}^N p_{ij}^{(n)} = 1$.
2. **Переход к пределу:** поскольку N **конечно**, можно поменять местами предел и сумму:

$$\lim_{n \rightarrow \infty} \left(\sum_{j=1}^N p_{ij}^{(n)} \right) = \sum_{j=1}^N \left(\lim_{n \rightarrow \infty} p_{ij}^{(n)} \right)$$

3. Противоречие:

Слева: предел константы 1 равен 1.

Справа: по предположению (пункт а) $\lim_{n \rightarrow \infty} p_{ij}^{(n)} = 0$ для всех j , следовательно сумма из N нулей равна 0.

Получаем: $1 = 0$ — противоречие.

Следовательно, для конечной ЦМ пункт (а) **невозможен**. □

Ковариация ошибок скорректированной модели: Матрица весов V :

- Обратная матрица ковариаций используется для взвешивания остатков (ОМНК).
- Обеспечивает эффективность оценок.

Коэффициенты корреляции:

- Вычисляются через элементы матриц поправок C_i, D_i .
- Учитываются при построении F-критерия.

Ковариационная структура ошибок скорректированной модели

Предварительные обозначения:

- $\mathbf{R}_i = \Lambda_{\nu_i} \mathbf{J}_i$ — масштабирующая матрица ($\nu_i \times T$).
- $\mathbf{P}_i = \mathbf{R}_i \Lambda_{iT} \mathbf{J}_i^T$ — матрица переходов ($\nu_i \times \nu_i$).
- $\mathbf{Q}_i = (\mathbf{I} - \mathbf{P}_i + \mathbf{P}_i^\infty)^{-1}$ — фундаментальная матрица.
- $\mathbf{C}_i = \mathbf{P}_i^\infty + \mathbf{Q}_i - \mathbf{I}$, $\mathbf{D}_i = \mathbf{Q}_i \mathbf{R}_i$.

Теорема (Ковариационная структура)

Ковариации ошибок скорректированных переменных ξ_{ij} и η_{ijt} имеют вид:

$$\text{Cov}(\xi_{ij}, \xi_{kl}) = \sigma_1^2 \delta_{ik} \delta_{jl} + \sigma^2 \tilde{D}_{ij,kl},$$

$$\text{Cov}(\eta_{ijt}, \eta_{kl\tau}) = \sigma^2 (\delta_{ik} \delta_{jl} \delta_{t\tau} - M_{ij,kl\tau} - M_{kl,ijt} + \tilde{D}_{ij,kl}),$$

где коэффициенты определяются через матрицы поправок:

$$\tilde{D}_{ij,kl} = F_0(i, k) + \delta_{ik} \Psi_{ij,kl}^{(i)}, F_0(i, k) = \sum_{t=1}^T \frac{b_{it} b_{kt}}{m_{\cdot t}} - \sum_{l=1}^I \frac{a_{il} a_{kl}}{m_{l\cdot}},$$

$$\Psi_{ij,kl}^{(i)} = \sum_{\nu=1}^{\nu_i} \frac{c_{j\nu}^{(i)} c_{l\nu}^{(i)}}{n_{i\nu}} - \sum_{\nu=1}^{\nu_i} \sum_{\tau \in N_{i\nu}} \left(\frac{c_{j\nu}^{(i)} d_{l\tau}^{(i)}}{n_{i\nu} m_{k\tau}} + \frac{d_{j\tau}^{(i)} c_{l\nu}^{(i)}}{n_{i\nu} m_{k\tau}} \right) + \sum_{t=1}^T \frac{d_{jt}^{(i)} d_{lt}^{(i)}}{m_{it}}.$$