

Методы улучшения классификации с приложением в медицине

Иванова Евгения Денисовна, 22.Б04-мм

Санкт-Петербургский государственный университет
Математико-механический факультет
Кафедра статистического моделирования

Научный руководитель: к.ф.-м.н., д. Алексеева Н.П.
Рецензент: старший научный сотрудник, ПСПбГМУ имени
академика И.П.Павлова Л. А. Белякова



Санкт-Петербург, 2026г.



Проблема медицинских данных

- высокая размерность признакового пространства;
- малое число наблюдений;
- скрытые нелинейные взаимодействия;
- неоднородность групп пациентов.

Объект исследования

Нейрофизиологические показатели пациентов с различной этиологией поражения мозга.

Цель работы

Исследование влияния преобразований полиномов Жегалкина на структуру разделимости классов пациентов в задаче прогнозирования состояния в коме, а также анализ изменения устойчивости нейрофизиологических эффектов и геометрии разделяющих расстояний между классами.

Задачи работы

- 1 Изучить методы анализа медицинских многомерных данных в условиях малых выборок и высокой размерности.
- 2 Рассмотреть булевы преобразования признаков на основе полиномов Жегалкина и XOR-операций.
- 3 Построить бинарные и Zh-комбинации нейрофизиологических признаков.
- 4 Исследовать влияние XOR-преобразований на качество LDA-классификации.
- 5 Проанализировать изменение разделимости классов с использованием расстояния Махаланобиса.
- 6 Исследовать эффекты смены знака влияния признаков при расслоении выборки с помощью полиномов Жегалкина.
- 7 Выявить группы устойчивых и неустойчивых признаков в зависимости от разбиения данных с помощью полиномов Жегалкина.

Выборка

- 100 пациентов;
- пациенты в коме;
- 4 группы восстановления.

Признаки

- возраст;
- пол;
- этиология;
- нейрофизиологические показатели.

Номер	Возр.	Пол	Этиол.	ВС	Латер. пр.	Латер. лев.	Парасаг.
1	43	1	2	2	-4.97	-5.08	-4.23
2	37	2	2	1	-1.47	-1.61	-2.95
3	32	1	1	1	-0.92	-0.84	-0.55
4	21	2	2	1	-4.51	-4.58	-5.25
5	33	2	2	4	-5.31	-5.80	-4.10

Фрагмент данных для анализа.

Информационный выигрыш

Информационная энтропия

$$H(Y) = - \sum_{i=1}^k p_i \log_2 p_i$$

Информационный выигрыш

$$IG = H(Y) - \frac{n_1}{n} H(Y_1) - \frac{n_2}{n} H(Y_2)$$

Обозначения: Y — классы восстановления, p_i — вероятность принадлежности объекта к i -му классу, n — размер выборки, n_1, n_2 — размеры подгрупп, k — число классов, $H(Y)$ — энтропия исходной выборки, $H(Y_1), H(Y_2)$ — энтропии соответствующих подвыборок.

Результат

$$age > 35, \quad IG = 0.0926$$

Бинаризация признаков

$$A = I(\textit{age} > 35)$$

$$G = I(\textit{gender} = 1)$$

$$E = I(\textit{etiology} = 1)$$

$$I(\textit{condition}) = \begin{cases} 1, & \text{если условие выполняется} \\ 0, & \text{иначе} \end{cases}$$

Полиномы Жегалкина

Булева функция может быть представлена в виде полинома Жегалкина над полем $\mathbb{F}_2 = \{0, 1\}$.

Общий вид полинома Жегалкина

$$f(x_1, \dots, x_n) = a_0 \oplus \bigoplus_i a_i x_i \oplus \bigoplus_{i < j} a_{ij} x_i x_j \oplus \dots$$

где $a_i \in \{0, 1\}$.

Далее будем называть полиномы Жегалкина Zh-полиномами, а полученные с их помощью комбинации — Zh-комбинациями.

Операция XOR $x \oplus y = (x + y) \bmod 2$.

Использование в работе

Для бинарных факторов были построены XOR-комбинации:

$$\begin{aligned} AG &= A \oplus G & AE &= A \oplus E \\ GE &= G \oplus E & AGE &= A \oplus G \oplus E \end{aligned}$$

Идея

Zh-комбинации позволяют выявлять скрытые нелинейные взаимодействия между клиническими факторами.

Линейный дискриминантный анализ

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

где:

- μ_k — средний вектор класса;
- Σ — общая ковариационная матрица;
- π_k — априорная вероятность класса.

Использование в работе

Сравнивались:

- LDA-классификация по нейрофизиологическим признакам;
- LDA-классификация после добавления XOR-факторов.

Результат

0.7284 → 0.7778

Расстояние Махаланобиса

Расстояние Махаланобиса является мерой статистической удалённости между двумя группами наблюдений (популяциями) с учётом корреляций между признаками и их масштаба изменчивости.

$$D_M = \sqrt{(\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2)}$$

где

- μ_1, μ_2 — векторы средних значений признаков в сравниваемых группах;
- Σ — объединённая ковариационная матрица;
- Σ^{-1} — обратная ковариационная матрица.

Использование в работе

Исследовалось изменение расстояний Махаланобиса между группами восстановления после добавления Zh-комбинаций в модель.

Теорема про ошибку классификации

Теорема

При инвариантности расстояний Махаланобиса

$$\Delta_0 = \Delta_1 = \Delta_2$$

расслоение не увеличивает ошибку классификации:

$$P_0 \geq sP_1 + (1 - s)P_2$$

- Δ_0 — расстояние Махаланобиса между исходными классами (без расслоения);
- Δ_1, Δ_2 — расстояния Махаланобиса после расслоения выборки на две подгруппы;
- P_0 — вероятность ошибки классификации в исходной (нерасслоенной) модели;
- P_1, P_2 — вероятности ошибки классификации в первой и второй подгруппах после расслоения;
- s — доля наблюдений, принадлежащих первой подгруппе после расслоения.

- 1 Построение базовой LDA-модели.
- 2 Добавление XOR-факторов в признаковое пространство.
- 3 Перебор бинарных и XOR-комбинаций.
- 4 Оценка качества классификации.
- 5 Построение Zh-комбинаций.
- 6 Анализ противоположных эффектов.
- 7 Анализ расстояний Махаланобиса.

Исследование

Было рассмотрено 127 Zh-комбинаций.

Таблица: Лучшие комбинации признаков

Комбинация признаков	Accuracy
A + AE	0.8272
A + AG + AE	0.8148
A + E + AG	0.8025

Краткий вывод:

- Использование Zh-комбинаций позволяет учесть структурные особенности данных при разбиении на подгруппы.
- Наибольшая точность (0.8272) достигается на комбинации из двух признаков.
- Качество классификации значительно улучшается при разбиении исходных данных на подгруппы.

Проверка влияния XOR-комбинаций

Проблема

Рост точности классификации

$$0.7284 \rightarrow 0.7778$$

может быть связан как с выявлением новых закономерностей, так и со случайными колебаниями выборки.

Подход

Для каждого пациента были вычислены:


$$P = \max_k P(Y = k|X)$$

где P — максимальная апостериорная вероятность принадлежности к одному из классов восстановления.

Проведён Repeated Measures ANOVA:

- внутрисубъектный фактор — модель (LDA и LDA+XOR);
- межсубъектный фактор — группа восстановления;
- зависимая переменная — максимальная апостериорная вероятность.

Результаты ANOVA



$$p_{\text{Group}} = 0.243, \quad p_{\text{Model}} = 0.556, \quad p_{\text{Group} \times \text{Model}} = 0.888$$

Вывод

Добавление XOR-комбинаций не приводит к статистически значимому увеличению максимальной апостериорной вероятности. Наблюдаемое увеличение ассигасы не сопровождается значимым изменением вероятностей

Противоположные эффекты

Нейрофизиологические признаки	Zh-комбинация=1	Zh-комбинация=0
Сенсомоторная кора справа	0.49	-5.67
Сенсомоторная кора слева	2.04	-6.33
Зрительная кора справа	3.04	-2.37
Мозжечок	2.78	-0.64

Интерпретация


- значения в столбцах Zh-комбинация=1 и Zh-комбинация=0 характеризуют различия между группами восстановления внутри соответствующих подгрупп пациентов;

Размер эффекта
$$d = \frac{\bar{x}_1 - \bar{x}_2}{s},$$

где $\bar{x}_1, \bar{x}_2$ — средние значения нейрофизиологического признака в двух сравниваемых группах восстановления, а s — общая оценка стандартного отклонения;

- положительный знак нейропризнаков означает лучшее восстановление.

Стабильность эффектов при Zh-разбиении



Красные точки — стабильный знак (FALSE)

Синие — изменение знака эффекта (TRUE)

Вывод

Zh-разбиение выявляет две группы признаков: стабильные и инвертирующие знак эффекта.

Распределение точек:

- FALSE: 210

- TRUE: 141

Интерпретация

- каждая точка соответствует одному признаку и одной паре групп восстановления;

- Точка:

$$(x, y) = (d_{Zh=0}, d_{Zh=1})$$

- отклонение от диагонали отражает изменение эффекта;
- около 40% эффектов меняют знак.

Существенно изменяющиеся расстояния

Zh-комбинация	Признак	Группы	D_1	D_0	ΔD
AG	мост	3–4	0.04	1.80	1.76
A	мост	2–3	0.20	1.87	1.67
AG	мост	1–4	0.09	1.73	1.64

Устойчивые расстояния

Zh-комбинация	Признак	Группы	D_1	D_0
A	левая поясная извилина	1–3	0.062	0.062
AGE	левая поясная извилина	1–4	0.383	0.383
G	мозжечок	2–3	0.326	0.327

D_1 — расстояние при Zh-комбинации=1, D_0 — расстояние при Zh-комбинации=0.

Основные результаты

- 1 Показано, что Zh-разбиения изменяют структуру делимости классов в пространстве признаков.
- 2 Установлено, что рост качества классификации не всегда сопровождается ростом устойчивости вероятностных оценок.
- 3 Показано, что часть нейрофизиологических признаков меняет знак влияния после Zh-разбиения, что указывает на неоднородность структуры данных.
- 4 Продемонстрированы существенные изменения расстояний Махаланобиса между классами после Zh-разбиений.
- 5 Установлено наличие двух типов признаков: устойчивых и инвертирующих знак влияния.

Основной вывод

Zh-разбиения позволяют выявлять скрытую структуру неоднородности данных, проявляющуюся в смене знака эффектов и изменении геометрии делимости классов.

Список литературы I

-  Алексеева Н.П. Симптомно-синдромальный анализ многомерных категориальных данных на основе полиномов Жегалкина. *Вестник Санкт-Петербургского университета. Математика. Механика. Астрономия*, 2021.
-  Алексеева Н.П. Анализ медико-биологических систем. Реципрокность, эргодичность, синонимия. Санкт-Петербургский государственный университет, Санкт-Петербург, 2012.
-  Жегалкин И.И. О технике вычислений предложений в символической логике. *Математический сборник*, 1927.
-  Cover T.M., Thomas J.A. *Elements of Information Theory*. Wiley, 2006.

-  Bishop C.M. *Pattern Recognition and Machine Learning*. Springer, 2006.
-  Mahalanobis P.C. On the generalized distance in statistics. *Proceedings of the National Institute of Sciences of India*, 1936.
-  Иванова Е. Методы улучшения классификации с приложениями в медицине. Zenodo, 2026. DOI: 10.5281/zenodo.20273349
<https://doi.org/10.5281/zenodo.20273349>