

Обобщенное обращение матриц в дисперсионном анализе медико-биологических данных

Дивногорская Анастасия Игоревна, 22.Б04-мм

Санкт-Петербургский государственный университет

Математико-механический факультет

Кафедра статистического моделирования

Научный руководитель: к.ф.-м.н., доцент Алексеева Н.П.

Рецензент: Кафедра общей математики и информатики,
старший преподаватель Барт В.А.



Санкт-Петербург, 2026



Цели и задачи работы:

- дать обзор теории обобщённого обращения матриц,
- рассмотреть практические методы построения и параметризации обобщенно обратных матриц,
- получить явные представления параметров однофакторной и двухфакторной (с взаимодействием бинарных факторов) дисперсионных моделей с помощью барицентрической параметризации,
- провести анализ реальных медико-биологических данных фтизиопульмонологического института Санкт-Петербурга (уровень металлопротеиназы-9).

Однофакторный дисперсионный анализ

Модель однофакторного дисперсионного анализа имеет вид:

$$\Omega_1 : \begin{cases} y_{ij} = \mu + \alpha_i + \varepsilon_{ij}, \quad i = 1, \dots, r; \quad j = 1, \dots, n_i \\ \{\varepsilon_{ij}\} \text{ независимы и распределены } N(0, \sigma^2). \end{cases}$$

В матричном виде ее можно записать как:

$$Y = X\beta + \varepsilon,$$

где: Y — вектор наблюдения, X — матрица плана, β — вектор параметров, ε — вектор ошибок.

Для оценки параметров используется метод наименьших квадратов (МНК): $\|Y - X\beta\| \rightarrow \min$.

Постановка задачи

Система нормальных уравнений МНК: $X^T X \beta = X^T Y$.

Для получения невырожденного решения на параметры статистической модели накладываются различные ограничения (например, $\sum \alpha_i = 0$).

Основная проблема

Если ограничения не вводить, информационная матрица $X^T X$ оказывается вырожденной. Применение псевдообратной матрицы приводит к единственному равномерному плану, что не охватывает всё множество возможных решений.

Предлагаемый подход

- Исследовать множество решений системы нормальных уравнений.
- Получить соответствующие оценки параметров.
- Для их перечисления использовать барицентрическую параметризацию обобщенно обратных матриц.

Псевдообратная матрица

Матрица A^- называется псевдообратной матрицей для матрицы A и обозначается как A^+ , если удовлетворяет условиям:

- (1) $AA^-A = A$,
- (2) $A^-AA^- = A^-$,
- (3) $(A^-A)^* = A^-A$,
- (4) $(AA^-)^* = AA^-$.

Определение

Для любой матрицы $A \in \mathbb{R}^{r \times n}$ обозначим за $A\{i, j, \dots, k\}$ множество всех таких матриц $A^- \in \mathbb{R}^{n \times r}$, которые удовлетворяют уравнениям $(i), (j), \dots, (k)$ из числа уравнений (1)-(4). Матрицу $A^- \in A\{i, j, \dots, k\}$ будем называть $\{i, j, \dots, k\}$ -обратной к A и обозначать как $A^{(i,j,\dots,k)}$.

Построение обобщенно обратных матриц

$$\nu(l|n) = \{(\nu_1, \nu_2, \dots, \nu_l) | \nu_1 < \nu_2 < \dots < \nu_l; \nu_i \in \mathbb{N}_n\}.$$

Матрица, составленная из строк 1_ν или из столбцов 1^ν единичной матрицы 1_n (или I_n), соответствующих множеству $\nu(l|n)$, называют ν -частичной.

Предложение [Барт, 2003]

Пусть для матрицы $A \in \mathbb{R}^{n \times m}$ ранга r берутся

$$\nu(r|n) = \{(\nu_1, \nu_2, \dots, \nu_r) | 1 \leq \nu_1 < \nu_2 < \dots < \nu_r \leq n\} \text{ и}$$

$$\lambda(r|m) = \{(\lambda_1, \lambda_2, \dots, \lambda_r) | 1 \leq \lambda_1 < \lambda_2 < \dots < \lambda_r \leq m\}, \text{ что } A_\lambda^\nu$$

не вырождена. Тогда $\{1\}$ -обратная имеет вид

$$A^- = (A_\lambda)^- A_\lambda^\nu (A^\nu)^-,$$

где A_λ и A^ν полного ранга, $(A_\lambda)^- \in (A_\lambda)\{1, 3\}$, и $(A^\nu)^- \in (A^\nu)\{1, 4\}$.

Барицентрическая параметризация

Пусть дана матрица $A \in \mathbb{R}^{k \times r}$ полного столбцового ранга. Тогда рассматривая всевозможные сочетания $\lambda = \lambda_t(r|k)$, такие, что $\Delta_t = \det A_{\lambda_t} \neq 0$, $\nabla_t = \det(A^-)^{\lambda_t}$, положим $a_t = \Delta_t \nabla_t$.

Введем равенство $\sum_t a_t = 1$. Приведем барицентрическую параметризацию $\{1\}$ - обратной матрицы следующей формулой:

$$A_{\nabla}^- = \sum^1 a_t A_{\lambda_t}^{-1} 1_{\lambda_t} + \sum^0 \nabla_t h_r \tilde{A}_{\lambda_t}^T h_r^T 1_{\lambda_t} = A_a^-(r, k) + A_0^-(r, k),$$

где:

- $\sum^1$ – суммирование по t , для которых $\Delta_t \neq 0$, а $\sum^0$ по оставшимся t ,
- $\tilde{A} - (r-1)$ -ассоциированная с A , A_0^- – аннулятор A ,
- $h_r = \sum_{t=1}^r (-1)^{t+1} 1^{[t]}(r, 1) 1_{[r-t+1]}(1, r)$,
- a_t – будем называть параметрами обращения.

Оценка параметров однофакторной модели с помощью барицентрической параметризации

Параметры модели однофакторного дисперсионного анализа

$\beta = (X^T X)^{-1} X^T Y$. Матрицу $X^T X$ обозначим через A .

$$A = \begin{pmatrix} n_1 + \dots + n_r & n_1 & \dots & n_r \\ n_1 & n_1 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ n_r & 0 & \dots & n_r \end{pmatrix}.$$

Вычисляем обобщенно обратную матрицу

$A^- = (A_\lambda)^- A_\lambda^\nu (A^\nu)^-$, где $\lambda = [2, 3, \dots, r+1]$,

$\nu = [2, 3, \dots, r+1]$. Тогда $\beta = A^- X^T Y$, Отсюда в явном виде можно выразить параметры модели:

$$\beta_0 = \sum_{i=1}^r \frac{\mu_i}{n_i} \sum_{j=1}^{n_i} y_{ij}, \quad \beta_1 = \bar{y}_1 - \beta_0, \quad \dots, \quad \beta_r = \bar{y}_r - \beta_0.$$

Интерпретация параметров обращения в однофакторной модели

Выбор параметров обращения $(\mu_1, \dots, \mu_r)$ определяет какой смысл имеет первый параметр модели β_0 :

Веса пропорциональные объемам групп

$(n_1/n, n_2/n, \dots, n_r/n)$

$$\beta_0 = \sum_{i=1}^r \frac{n_i}{n} \bar{y}_i - \text{общее среднее.}$$

Равные веса $(1/r, 1/r, \dots, 1/r)$

$$\beta_0 = \frac{1}{r} \sum_{i=1}^r \bar{y}_i - \text{среднее групповых средних.}$$

Выделенная группа (например: $(1, 0, \dots, 0)$)

$$\beta_0 = \bar{y}_1 - \text{среднее по первой группе.}$$

При весах пропорциональных объемам групп

$(n_1/n, n_2/n, \dots, n_r/n)$ оценки параметров модели совпадают со стандартными в дисперсионном анализе.

$$\beta_0 = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} y_{ij} = \bar{y}, \quad \beta_i = \bar{y}_i - \beta_0, \quad i = 1, \dots, r.$$

Такая параметризация соответствует классическому ограничению $\sum_{i=1}^r n_i \beta_i = 0$.

При выделении одной группы например $(1, 0, \dots, 0)$, получаем

$$\beta_0 = \bar{y}_1, \quad \beta_1 = 0, \quad \beta_i = \bar{y}_i - \bar{y}_1, \quad i = 2, \dots, r.$$

В этом случае ограничение на параметры принимает вид $\sum_{i=1}^r n_i \beta_i = n(\bar{y} - \bar{y}_1)$.

Двухфакторный дисперсионный анализ

Рассматриваем модель двухфакторного дисперсионного анализа с дихотомическими факторами X_1 и X_2 .

Эффект симптома γ_i (где $i = 1, 2$) будем вычислять по правилу

$$X_{12} = |X_1 - X_2| = X_1 + X_2 \pmod{2}$$

И будем рассматривать его в качестве взаимодействия факторов в нашей модели.

$$\Omega_2 : \begin{cases} y_{ijk} = \mu + \alpha_j + \beta_i + \gamma_l + \varepsilon_{ijk}, & i, j = 1, 2; \quad l = i + j \pmod{2}; \\ & k = 1, \dots, n_{ij} \\ \{\varepsilon_{ijk}\} \text{ независимы и распределены } N(0, \sigma^2). \end{cases}$$

Матричная модель двухфакторного дисперсионного анализа

Перейдем к матричной записи модели $Y = X\hat{\Theta} + \varepsilon$, где $\hat{\Theta} = (X^T X)^{-1} X^T Y$. Найдем матрицу $X^T X$, обобщенно обратная матрица не зависит от выбора невырожденного блока, поэтому берем $\lambda = [1, 2, 4, 6]$.

$$(X^T X)_{[1,2,4,6]} =$$
$$= \begin{bmatrix} n & n_1 + n_3 & n_0 + n_2 & n_2 + n_3 & n_0 + n_1 & n_1 + n_2 & n_0 + n_3 \\ n_1 + n_3 & n_1 + n_3 & 0 & n_3 & n_1 & n_1 & n_3 \\ n_2 + n_3 & n_3 & n_2 & n_2 + n_3 & 0 & n_2 & n_3 \\ n_1 + n_2 & n_1 & n_2 & n_2 & n_1 & n_1 + n_2 & 0 \end{bmatrix}$$

Здесь $n_{11} = n_0$, $n_{12} = n_1$, $n_{21} = n_2$, $n_{22} = n_3$.

Оценка параметров двухфакторной модели

Найдем оценку первого параметра в общем случае. Будем рассматривать только 4 минора, выбрав параметрами обращения соответственного m_1, m_2, m_3, m_4 .

$$\hat{\Theta}_1 = \hat{\mu} = m_1 \overline{Y_{11}} + m_2 \overline{Y_{21}} + m_3 \overline{Y_{12}} + m_4 \overline{Y_{22}}$$

$$\hat{\Theta}_2 = \hat{\alpha}_2 = \frac{m_1 + m_2}{2} (\overline{Y_{22}} - \overline{Y_{21}} + \overline{Y_{12}} - \overline{Y_{11}})$$

$$\hat{\Theta}_3 = \hat{\alpha}_1 = \frac{m_3 + m_4}{2} (-\overline{Y_{22}} + \overline{Y_{21}} - \overline{Y_{12}} + \overline{Y_{11}})$$

$$\hat{\Theta}_4 = \hat{\beta}_2 = \frac{m_1 + m_3}{2} (\overline{Y_{22}} + \overline{Y_{21}} - \overline{Y_{12}} - \overline{Y_{11}})$$

$$\hat{\Theta}_5 = \hat{\beta}_1 = \frac{m_2 + m_4}{2} (-\overline{Y_{22}} - \overline{Y_{21}} + \overline{Y_{12}} + \overline{Y_{11}})$$

$$\hat{\Theta}_6 = \hat{\gamma}_1 = \frac{m_1 + m_4}{2} (-\overline{Y_{22}} + \overline{Y_{21}} + \overline{Y_{12}} - \overline{Y_{11}})$$

$$\hat{\Theta}_7 = \hat{\gamma}_2 = \frac{m_2 + m_3}{2} (\overline{Y_{22}} - \overline{Y_{21}} - \overline{Y_{12}} + \overline{Y_{11}})$$

Интерпретация параметров обращения в двухфакторной модели

Выбор параметров обращения (m_1, m_2, m_3, m_4) определяет какой смысл имеет первый параметр модели $\hat{\mu}$:

Веса пропорциональные объемам групп

$(n_0/n, n_1/n, n_2/n, n_3/n)$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^2 \sum_{j=1}^2 \sum_{k=1}^{n_{ij}} y_{ijk} - \text{общее среднее.}$$

Равные веса $(1/4, 1/4, 1/4, 1/4)$

$$\hat{\mu} = \frac{1}{4} \sum_{i=1}^2 \sum_{j=1}^2 \bar{Y}_{ij} - \text{среднее групповых средних.}$$

Выделенная группа (например: $(1, 0, 0, 0)$)

$$\hat{\mu} = \bar{Y}_{11} - \text{среднее по группе.}$$

На основе полученных оценок будем рассчитывать статистику для проверки гипотез об отсутствии эффекта факторов и взаимодействия.

Предложение (Инвариантность остаточной суммы квадратов полной модели)

Остаточная сумма квадратов основной модели $R_0^2 = \sum_{i=1}^2 \sum_{j=1}^2 \sum_{k=1}^{n_{ij}} (y_{ijk} - \hat{\mu} - \hat{\alpha}_j - \hat{\beta}_i - \hat{\gamma}_l)^2$ совпадает с остаточной суммой квадратов, получаемой при использовании стандартных МНК-оценок.

Статистика F будет рассчитываться по формуле

$F = \frac{n-JI}{J-1} \frac{R_1^2 - R_0^2}{R_0^2}$, где $J = I = 2$ - количество уровней факторов X_1, X_2 ; R_1^2 - остаточная сумма квадратов усеченной модели.

Однофакторный дисперсионный анализ реальных данных

Для иллюстрации теоретических результатов, полученных в работе, проведён анализ реальных медико-биологических данных из фтизиопульмонологического института Санкт-Петербурга.

- В качестве зависимой переменной выступает уровень металлопротеиназы-9 (ММП-9) — биомаркер, связанный с процессами ремоделирования тканей лёгких и воспалением.
- В качестве категориального фактора рассматриваются всевозможные комбинации двух признаков:
 - нарушение функции внешнего дыхания (0 — нет нарушений, 1 — есть);
 - диагноз (ИТЛ, туберкулёма, ФКТ).


Значение статистики для однофакторного анализа

Используя найденные оценки параметров, были вычислены значения статистики F для различных наборов параметров обращения.

Параметры обращения	Комбинация	F
$(n_1/n, n_2/n, n_3/n, n_4/n, n_5/n, n_6/n)$		3.3147
$(1/6, 1/6, 1/6, 1/6, 1/6, 1/6)$		4.4146
$(1, 0, 0, 0, 0, 0)$	[0 - ИТЛ]	17.0310
$(0, 1, 0, 0, 0, 0)$	[0 - туберкулема]	3.9272
$(0, 0, 1, 0, 0, 0)$	[0 - ФКТ]	4.1362
$(0, 0, 0, 1, 0, 0)$	[1 - ИТЛ]	13.7301
$(0, 0, 0, 0, 1, 0)$	[1 - туберкулема]	8.3709
$(0, 0, 0, 0, 0, 1)$	[1 - ФКТ]	4.7492

Во всех рассмотренных вариантах значение статистики F превышает критическое значение (примерно 2.3 при $\alpha = 0.05$).

Корреляция с контрастным анализом



Коэффициент корреляции Спирмена между полученными значениями статистики и результатами контрастного анализа равен 0.6.

В двухфакторной модели с эффектом взаимодействия (представленным через эффект симптома) рассматриваются два бинарных фактора:

- Фактор X_1 — нарушение функции внешнего дыхания (0 — нет нарушений, 1 — есть);
- Фактор X_2 — лекарственная чувствительность (0 — лекарственная устойчивость, 1 — чувствительность).

В качестве зависимой переменной остается уровень металлопротеиназы-9 (ММП-9).

Значение статистики для двухфакторного анализа

Для проверки гипотез об отсутствии главных эффектов и взаимодействия были рассчитаны соответствующие статистики при различных параметрах барицентрической параметризации.

Параметры обращения	F_α	F_β	F_γ
$(n_0/n, n_1/n, n_2/n, n_3/n)$	0.0682	1.0089	2.095
$(1/4, 1/4, 1/4, 1/4)$	0.1512	1.2097	2.3579
$(1, 0, 0, 0)$	0.0784	3.4051	6.2877
$(0, 1, 0, 0)$	0.0784	1.4337	3.1438
$(0, 0, 1, 0)$	0.5265	3.4051	3.1438
$(0, 0, 0, 1)$	0.5265	1.4337	6.2877

Эффекта взаимодействия значим при параметрах обращения $(1, 0, 0, 0)$ и $(0, 0, 0, 1)$. Значение статистики главных эффектов факторов X_1, X_2 не превышает критического (примерно 3.94 при $\alpha = 0.05$).

Заключение

- Дан обзор теории обобщенного обращения матриц и ее применение к задачам дисперсионного анализа медико-биологических данных.
- Рассмотрены практические построения и параметризации обобщенно обратных матриц.
- С помощью барицентрической параметризации для однофакторной модели получены явные выражения оценок параметров через взвешенные средние групповых значений. Для двухфакторной модели с бинарными факторами выведены общие формулы оценок всех параметров модели в зависимости от четырёх параметров обращения.
- На реальных данных продемонстрировано практическое применение разработанного подхода. Выявлена статистическая значимость факторов и их взаимодействия в зависимости от выбора параметров обращения.

Список литературы

-  1. Барт А. Г. Анализ медико-биологических систем. Метод частично обратных функций. — СПбГУ, 2003.
-  2. Алексеева Н. П. Реципрокность, эргодичность, синонимия.— СПбГУ, 2012.
-  3. Г. Шеффе. Дисперсионный анализ. — Москва "Наука", 1980.
-  4. A. Ben-Israel. Generalized inverses: theory and applications. — Springer, 2003.
-  5. C. R. Rao, S.K. Mitra. Generalized inverse of matrices and its Applications. — John Wiley & Sons, Inc, 1971.

-  6. C. R. Rao. Linear Statistical Inference and its Applications. — John Wiley & Sons, Inc, 1973.
-  7. R. Penrose. A generalized inverse for matrices. — Mathematical Proceedings of the Cambridge Philosophical Society, 1955.
-  8. А. Дивногорская. Вычисление вектора параметров и статистик для дисперсионного анализа [Электронный ресурс] : computational notebook. — Zenodo, 2026. — DOI: 10.5281/zenodo.20345339.