

Один робастный алгоритм оценивания главных компонент

Сыткин Артем Валерьевич

Санкт-Петербургский государственный университет
Прикладная математика, программирование и искусственный интеллект
Вычислительная стохастика и статистические модели

Научный руководитель: д.ф.-м.н., профессор Ермаков М.С.,
кафедра статистического моделирования



28.05.2026

- $X = \{x_i\}_{i=1}^d$, $x_i \in \mathbb{R}^n$ — выборка
- Центрирование: $z_i = x_i - \bar{x}$, $Z = \{z_i\}_{i=1}^n$
- PCA — метод для выделения направлений максимальной вариации

Цель: Найти $w_1, \dots, w_k$, $\|w_j\| = 1$, $w_i \perp w_j$

$$w_1 = \arg \max_{\|w\|=1} w^\top \Sigma w$$

PCA

- $\Sigma = \frac{1}{n} \sum_{i=1}^n Z_i Z_i^\top \in \mathbb{R}^{d \times d}$ - ковариационная матрица
- $\Sigma = U \Lambda U^\top$, - разложение
- $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$, $\lambda_1 \geq \dots \geq \lambda_d \geq 0$. - собственные числа и соответствующие вектора
- $w_j = v_j$, $v_j \leftrightarrow \lambda_j$

Цель: исследовать новый алгоритм оценки главных компонент, основанный на последовательном построении линейных регрессий

Задачи:

- Реализовать предложенный алгоритм в изначальном варианте, провести анализ его сходимости
- Исследовать его робастное обобщение на основе квантильной регрессии
- Сравнить на модельных данных результаты работы с существующими версиями РСА

Робастные оценки ковариации

- M-estimators of scatter
- MCD, S-estimators

Projection Pursuit

- Projection Pursuit PCA
- ROBPCA

Low-rank методы

- Robust PCA ($X = L + S$)

Общий принцип: существующие методы строятся через робастную оценку ковариации, либо поиск направлений максимального разброса.

В данной работе рассматривается иной подход — оценка компонент с помощью последовательного построения регрессионных моделей.

Формализуем идею алгоритма и введем обозначения.

Обозначения

- $X \in \mathbb{R}^{n \times d}$ - центрированные данные
- $S := \frac{1}{n} X^\top X \in \mathbb{R}^{d \times d}$ - ковариационная матрица
- $S = U \Lambda U^\top$, где $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$, $\lambda_1 > \lambda_2 \geq \dots \geq \lambda_d \geq 0$, а U - ортогональная матрица собственных векторов
- Для ортогональной матрицы Q положим $S(Q) := Q^\top S Q$
- $\text{offdiag}(A)$ - матрица, в которой диагональные элементы занулены, а вне диагонали совпадают с A .

Алгоритм постепенно выравнивает первый столбец текущей матрицы Q_k с u_1 и состоит из последовательности поворотов $G_{pq}(\theta)$ в плоскостях с индексами $(1, q)$, $q = 2, \dots, d$. Углы поворотов получаются из построения МНК-регрессий на нынешнем шаге.

Алгоритм И-МНК

- ❶ **Инициализация:** $Q_0 \in O(d)$, $Q_0 = I$, $S_0 := S(Q_0)$.
- ❷ **На шаге k выполняем один проход по $q = 2, \dots, d$:**
 - ❶ Для пары $(1, q)$ вычисляем угол наклона регрессии:
❷ $\theta_{1q} := \arctan \left(\frac{(S_k)_{1q}}{(S_k)_{11}} \right)$.
 - ❸ Обновляем матрицу поворота и ковариационную матрицу:
 - ❹ $Q \leftarrow Q G_{1q}(\theta_{1q})$, $S \leftarrow G_{1q}(\theta_{1q})^\top S G_{1q}(\theta_{1q})$.
- ❸ **Повторение:** Полученную пару (Q_{k+1}, S_{k+1}) используем в следующей итерации.

Рассмотрим двумерный блок текущей ковариационной матрицы:

$$B = \begin{pmatrix} a & b \\ b & d \end{pmatrix} = \begin{pmatrix} (S_k)_{11} & (S_k)_{1q} \\ (S_k)_{1q} & (S_k)_{qq} \end{pmatrix}$$

Поворот выполняется с углом $\theta_{1q} = \arctan\left(\frac{b}{a}\right)$.

Свойство 1: уменьшение внедиагонального элемента

После поворота:

$$(S_{k+1})_{1q} = \frac{d}{a}(S_k)_{1q} + O\left(\frac{(S_k)_{1q}^3}{a^2}\right).$$

Следовательно, если $a > d$, то связь между координатами уменьшается.

Свойство 2: перенос дисперсии

$$(S_{k+1})_{11} - (S_k)_{11} = \frac{((S_k)_{qq} + (S_k)_{11})(S_k)_{1q}^2}{(S_k)_{11}^2 + (S_k)_{1q}^2} \geq 0.$$

Дисперсия вдоль первой координаты монотонно возрастает.

Пусть

$$S = U\Lambda U^\top, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d),$$
$$\lambda_1 > \lambda_2 \geq \dots \geq \lambda_d, \quad \rho = \max_{q \geq 2} \frac{\lambda_q}{\lambda_1} = \frac{\lambda_2}{\lambda_1} < 1.$$

Предположим, что текущая матрица S_k достаточно близка к диагональной форме.

Тогда после прохода по всем q , можно утверждать о следующей оценке внедиагональных элементов:

$$\max_{q \geq 2} |(S_{k+1})_{1q}| \leq (\rho + \delta) \max_{q \geq 2} |(S_k)_{1q}| + C\varepsilon^2.$$

Теорема о сходимости

Последовательность направлений $v_k = Q_k e_1$ линейно сходится к первой главной компоненте:

$$v_k \rightarrow \pm u_1.$$

Скорость сходимости:

$$\|v_k - u_1\| = O(\rho^k).$$

Итерационная квантильная регрессия (И-КР)

Пусть наблюдения:

$$X = \{x_i\}_{i=1}^n, x_i \in \mathbb{R}^n, z_i = x_i - \text{mean}(x), Z = \{z_i\}_{i=1}^n$$

- Инициализируем матрицу поворота:

$$Q = I_n$$

- Для фиксированной координаты $Z_1, \forall q \geq 2$ рассматриваем регрессию:

$$(\alpha_q, \beta_q) = \arg \min_{\alpha, \beta} \sum_{i=1}^n |Z_{iq} - \alpha - \beta Z_{i1}|$$

- Определяем вектор v :

$$v = \frac{(1, \beta_2, \dots, \beta_n)}{\sqrt{1 + \sum_{q=2}^n \beta_q^2}}$$

- Рассматриваем матрицу A и ее QR-разложение:

$$A = \begin{bmatrix} v & I_{n \times n}^{(-1)} \end{bmatrix}, \quad A = Q_{\text{step}} R$$

- Тогда столбцы Q_{step} :

$$q_1 = \frac{v}{\|v\|}, \quad q_2, \dots, q_n - \text{дополняют до ортонормированного базиса}$$

- Q_{step} задает ортонормальную замену базиса:

$$Q_{\text{step}} = [q_1 \quad q_2 \quad \dots \quad q_n], \quad Q_{\text{step}}^\top Q_{\text{step}} = I, \quad x' = Q_{\text{step}}^\top x,$$

- Тогда новая система координат имеет первую ось:

$$e'_1 = q_1 = \frac{v}{\|v\|} - \text{направление, совпадающее с } v,$$

$$Z \leftarrow Z Q_{\text{step}}, \quad Q \leftarrow Q Q_{\text{step}}$$

- Отображение ортогональное, а значит мы производим следующий поворот:

$$Z_{\text{new}} = Z Q_{\text{step}}, \quad Q_{\text{new}} = Q Q_{\text{step}}$$

Ключевые вопросы для экспериментов

- Как соотносятся результаты И-КР, обычного PCA и ROBPCA на разных данных?
- Насколько метод устойчив к выбросам и нелинейностям?


Проведение испытания и сравнение алгоритмов

Генерируем данные, применяем все три метода, после чего добавляем выбросы и смотрим на новые главные компоненты, анализируем изменения после появления выбросов.


Для численного сравнения качества алгоритмов были выбраны следующие условия моделирования данных:

- $\mathbb{R}^2$; $X \sim \mathcal{N}(0, 1)$, $Y \sim \mathcal{N}(0, 1.1)$
- геометрия выбросов: под углом от $\frac{\pi}{10}$ до $\frac{\pi}{2}$ к $(0, 0)$ с шагом $\pi/10$, расстояние от $(0, 0)$: от 3 до 15 с шагом в 3
- объем выбросов: от 10 до 50 процентов с шагом в 10

2D визуализация главных направлений



2D визуализация главных направлений




До/после добавления 30 процентов выбросов, $3\pi/10$, радиус 10
Разница в угле наклона главной компоненты до/после выбросов:

- PCA: 0.926
- ROBPCA: 0
- И-КР: 0.392


Доля выбросов	PCA	ROBPCA	И-КР
10%	0.92/1.54	0.00/0.00	0.22/0.43
20%	0.93/1.54	0.00/0.00	0.32/0.65
30%	0.94/1.56	0.00/0.00	0.43/0.74
40%	0.94/1.57	0.91/1.53	0.67/1.04
50%	0.94/1.57	0.93/1.55	0.86/1.05

В таблице указаны среднее/максимальное отклонения направления первой главной компоненты по всем рассмотренным положениям выбросов.

2D визуализация главных направлений



2D визуализация главных направлений



В рамках выполнения работы были получены следующие результаты

- В этой работе был предложен и рассмотрен итерационный алгоритм оценивания векторов метода главных компонент на основе оценок параметров линейной регрессии
- Была доказана теорема о сходимости его варианта на основе использования метода наименьших квадратов к векторам метода главных компонент и получена оценка скорости сходимости.
- Метод было обобщен на робастные оценки, получаемые с помощью квантильной регрессии. Численные эксперименты на модельных данных показали, что предложенный подход обеспечивает качественное оценивание главных компонент.

-  Candès E. J., Li X., Ma Y., Wright J. Robust Principal Component Analysis? // arXiv preprint arXiv:0912.3599, 2009.
-  Bouwmans T., Aybat N. S., Zahzah E.-H. Handbook of Robust Low-Rank and Sparse Matrix Decomposition Applications. CRC Press, 2016.
-  Gray V. Principal Component Analysis: Methods, Applications and Technology. Nova Science Publishers, 2017.
-  Hubert M., Rousseeuw P. J., Van Aelst S. High-Breakdown Robust Multivariate Methods // Statistical Science. 2008. Vol. 23, No. 1. P. 92–119.
-  Maronna R. A. Robust M-Estimators of Multivariate Location and Scatter // The Annals of Statistics. 1976. Vol. 4, No. 1. P. 51–67.
-  Campbell N. A. Robust Procedures in Multivariate Analysis I: Robust Covariance Estimation // Applied Statistics. 1980. Vol. 29, No. 3. P. 231–237.

-  Croux C., Haesbroeck G. Principal Component Analysis Based on Robust Estimators of the Covariance or Correlation Matrix: Influence Functions and Efficiencies // Biometrika. 2000. Vol. 87, No. 3. P. 603–618.
-  Li G., Chen Z. Projection-Pursuit Approach to Robust Dispersion Matrices and Principal Components: Primary Theory and Monte Carlo // Journal of the American Statistical Association. 1985. Vol. 80, No. 391. P. 759–766.
-  Croux C., Ruiz-Gazen A. A Fast Algorithm for Robust Principal Components Based on Projection Pursuit // COMPSTAT Proceedings. 1996. P. 211–216.
-  Croux C., Ruiz-Gazen A. High Breakdown Estimators for Principal Components: The Projection-Pursuit Approach Revisited // Journal of Multivariate Analysis. 2005. Vol. 95, No. 1. P. 206–226.
-  Hubert M., Rousseeuw P. J., Verboven S. A Fast Method for Robust Principal Components with Applications to Chemometrics // Chemometrics and Intelligent Laboratory Systems. 2002. Vol. 60, No. 1–2. P. 101–111.

Спасибо за внимание!