

Исследование и развитие робастного стохастического алгоритма оценки многомерного параметра положения распределения

Филатова Арина Алексеевна, гр. 24.M22-мм

Санкт-Петербургский государственный университет
Математическое моделирование, программирование и
искусственный интеллект

Научный руководитель: д.ф.-м.н., профессор М.С. Ермаков

Рецензент: к.ф.-м.н., с.н.с. В.А. Проурзин

Санкт-Петербург, 2026

Введение. Проблема многомерного робастного оценивания

Одномерный случай

Оценки параметра положения и разброса хорошо известны:

- Традиционные — выборочное среднее и дисперсия;
- Робастные — выборочная медиана и MAD.

Многомерный случай

- Традиционные — выборочный вектор средних и ковариационная матрица;
- Робастные — не определяются однозначно. Есть несколько оценок параметра положения и матрицы разброса, каждые со своими трудностями.

- ★ **Покомпонентные методы** (покоординатная медиана, GK)
 - вычислительно просты;
 - но не эквивариантны даже относительно вращений.
- ★ **Аффинно-эквивариантные методы** (медиана Тьюки, медиана Оджа, MCD)
 - обладают хорошими теоретическими свойствами;
 - но вычислительно сложны.
- ★ **Проекционные методы** (проекционная медиана)
 - эквивариантны относительно вращений;
 - но существующие алгоритмы недостаточно эффективны.

Цель работы

Разработка вычислительно эффективных робастных алгоритмов оценивания параметра положения и матрицы разброса многомерных данных, эквивариантных относительно вращений.

Почему важна эквивариантность относительно вращений?

- Результаты не зависят от выбора системы координат;
- Упрощается исследование асимптотических свойств и предельных распределений оценок;
- Открывается возможность построения доверительных областей в многомерном случае.

Алгоритм 1: Предложенная оценка параметра положения

- 1 Рассматриваем выборку $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, $\mathbf{x}_i \in \mathbb{R}^d$.
- 2 Произвольным образом выбираем точку $\hat{\mathbf{m}}_1$ — начальное приближение. Задаем критерий останова. Полагаем $i = 1$.
- 3 Моделируем случайный вектор $\mathbf{u}_i \in \mathbb{R}^d$, равномерно распределенный на единичной сфере. Проводим прямую

$$l_i = \{\hat{\mathbf{m}}_i + \lambda \mathbf{u}_i, \lambda \in \mathbb{R}\}.$$

- 4 Проектируем наблюдения $\mathbf{x}_1, \dots, \mathbf{x}_n$ на прямую l_i , получаем точки-проекции $y_{i1}, \dots, y_{in}$.
- 5 Находим медиану $\hat{\mathbf{m}}_{i+1}$ точек $y_{i1}, \dots, y_{in}$.
- 6 Алгоритм завершается, когда выполняется критерий останова, например, $\|\hat{\mathbf{m}}_i - \hat{\mathbf{m}}_{i+1}\| < \varepsilon$. Иначе увеличиваем счётчик шагов i на 1 и возвращаемся к шагу 3.

Эквивалентные определения проекционной медианы

Пусть ω — случайный вектор, равномерно распределённый на единичной сфере Ω_d .

Проекционная медиана [Durocher and Kirkpatrick, 2009] определяется как

$$M_p(\mathbf{X}) = d \mathbb{E}_{\omega} \text{med}(\mathbf{X}_{\omega}), \quad (1)$$

где $\mathbf{X}_{\omega}$ — проекция выборки на направление ω .

Метод уаттм [Chen and Nason, 2020]

Рассматривается задача минимизации функционала

$$\hat{\mu} = \arg \min_{\mu \in \mathbb{R}^d} \mathbb{E}_{\omega} m_{\mathbf{X}}(\mu, \omega)^2, \quad (2)$$

где

- $\mu \in \mathbb{R}^d$ — вектор сдвига;
- $\mathbf{y} = (\mathbf{X} - \mathbf{1}_n \mu^T) \omega$ — проекция выборки $\mathbf{X}$ на ω после сдвига начала координат в точку μ ;
- $m_{\mathbf{X}}(\mu, \omega) = \text{med}(\mathbf{y})$ — одномерная медиана проекций.

Теорема [Chen and Nason, 2020]

Для любой конечной выборки $\mathbf{X}$ оценка уаттм (2) эквивалентна проекционной медиане (1).

Связь Алгоритма 1 с проекционной медианой

Мной была доказана следующая теорема.

Теорема

Алгоритм 1 является методом стохастического градиента для оптимизации целевой функции метода уатт (2) с длиной шага $\alpha = 0,5$.

Таким образом, Алгоритм 1 оптимизирует тот же функционал, что и метод уатт, а значит, в случае сходимости вычисляет оценку, **эквивалентную проекционной медиане.**

Следовательно, получаемая оценка (стохастическая медиана) наследует основные свойства проекционной медианы:

- ❶ эквивариантность относительно:
 - сдвигов;
 - вращений;
 - равномерного масштабирования;
- ❷ высокая робастность: $\text{breakdown point} = \frac{1}{2}$.

Модификации для повышения устойчивости

Проблемы базового алгоритма:

- Абсолютный критерий останова не учитывает масштаб данных;
- Из-за случайности направлений возможна преждевременная остановка.

Методы решения:

1 Относительный критерий останова

$$\|\hat{\mathbf{m}}_i - \hat{\mathbf{m}}_{i+1}\| < \varepsilon \|\hat{\mathbf{m}}_i\|.$$

Позволяет учитывать масштаб текущего приближения.

2 Минимальное число итераций $k_{\min}$

Алгоритм обязан выполнить не менее $k_{\min}$ шагов.

3 Многократное выполнение критерия останова

Алгоритм завершается только после того, как критерий останова выполнится c раз.

Влияние модификаций на устойчивость

Эксперимент: 100 запусков для каждого метода на закоррелированной выборке из многомерного нормального распределения ($d = 3, n = 1000$).




Рис.: Распределение $\|\hat{\mathbf{m}} - \mathbf{m}\|$ для различных модификаций

Модификации для повышения точности

Проблема: Наличие проекции на случайное направление не позволяет алгоритму сойтись точно в искомую точку (эффект «блуждания» вокруг оптимума).

Методы решения:

1 Усреднение последних приближений

Сглаживание итогового результата по дополнительным k

итерациям: $\hat{\mathbf{m}}_{\text{avg}_k} = \frac{1}{k} \sum_{i=N+1}^{N+k} \hat{\mathbf{m}}_i.$

2 Сглаживание траектории оптимизации

Использование экспоненциального сглаживания для траектории метода оптимизации: $\tilde{\mathbf{m}}_i = \alpha \hat{\mathbf{m}}_i + (1 - \alpha) \tilde{\mathbf{m}}_{i-1}$, где $\tilde{\mathbf{m}}_i$ — траектория модифиц. алгоритма, а $\hat{\mathbf{m}}_i$ — шаг из точки $\tilde{\mathbf{m}}_{i-1}$ базовым Алгоритмом 1, α — параметр сглаживания.

3 Адаптивный шаг (Модификация AdaGrad)

Автоматическая подстройка величины шага γ_i на i -й итерации:
 $\alpha = \gamma_i, \{\gamma_i\}$ — затухающая последовательность.

Сравнение модификаций

Эксперимент: 100 запусков для каждого метода на закоррелированной выборке из многомерного нормального распределения ($d = 3, n = 1000$).





Рис.: Распределение $\|\hat{\mathbf{m}} - \mathbf{m}\|$ для различных модификаций


Случай, когда алгоритм не сходится

Эксперимент: 200 запусков для каждого метода на выборке из $n = 3000$ точек, образующих букву V.


● Выборка ● Стохастическая ★ Среднее ст. медиан ■ Оджа ▲ Тьюки ◆ Геометрическая



(a) Базовый



(b) Экс. сглаживание




(c) AdaGrad


Случай, когда алгоритм не сходится

Эксперимент: 200 запусков для каждого метода *с усреднением* на выборке из $n = 3000$ точек, образующих букву V.


● Выборка ● Стохастическая ★ Среднее ст. медиан ■ Оджа ▲ Тьюки ◆ Геометрическая



(a) Базовый



(b) Экс.сглаживание



(c) AdaGrad

Задача оценивания матрицы разброса

Некоторые современные методы построения робастных оценок вычисляют одновременно пару из оценок параметра положения и матрицы разброса.

Идея 1: модифицировать Алгоритм 1 так, чтобы помимо оценки параметра положения он мог в то же время оценить и матрицу разброса.

Идея 2: поставим задачу оценивания матрицы разброса S для некоторой выборки так, чтобы приближенно выполнялось соотношение, подобное дисперсии линейного преобразования многомерной случайной величины, то есть

$$s_u^2 \approx \mathbf{u}^T S \mathbf{u}, \quad (3)$$

где $\mathbf{u}$ — случайное направление на единичной сфере, s — некая робастная оценка разброса одномерных данных.

Возьмём $s_u^2 = c \cdot \text{MAD}_u^2 = \widehat{\text{MAD}}_u^2$, c — нормирующий множитель.

Алгоритм 2: Наивный подход к алгоритму оценивания матрицы разброса

Решение: промоделировать случайные направления $\mathbf{u}_i$, вычислить $\widehat{\text{MAD}}_{\mathbf{u}_i}^2$, свести вычисление оценки к решению СЛАУ.

- 1 Рассматриваем выборку $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, задаём K — общее число шагов, $K \geq r$.
- 2 Моделируем $\mathbf{u}_1, \dots, \mathbf{u}_K$ — случайные направления на единичной $(d - 1)$ -мерной сфере.
- 3 Считаем $\widehat{\text{MAD}}_{\mathbf{u}_i}^2$ проекции выборки $\mathbf{X}$ на направления $\mathbf{u}_i$ для всех $i = 1, \dots, K$.
- 4 Составляем СЛАУ на элементы $s_1, \dots, s_K$ матрицы $\mathbf{S}$ используя соотношение (3), общее число уравнений получится равным K . Обозначим под $\hat{\mathbf{X}} \in \mathbb{R}^{K \times r}$ левую часть СЛАУ, под $\mathbf{z} \in \mathbb{R}^K$ правую. $\mathbf{z}$ содержит вычисленные MAD , строки левой получены с помощью $\mathbf{u}_i$.
- 5 Найдём приближенное решение через псевдообратную $\hat{\mathbf{s}} = \hat{\mathbf{X}}^- \mathbf{z}$, полученные значения подставляем в оценку $\hat{\mathbf{S}}$.

Алгоритм 2: анализ

Плюсы: эквивариантен относительно вращений.

Минусы: матрица-регрессор случайна, может быть плохо обусловленной, поэтому алгоритм численно неустойчив.

В [Devlin et al., 1981] дан способ оценки $\tilde{\mathbf{S}}$: для пары случайных величин X_j и X_k и «функции, оценивающей среднеквадратическое отклонение» $\sigma()$, элементы матрицы разброса $\mathbf{S} = (s_{jk})$ определяются следующим образом:

$$s_{jk} = \frac{\sigma(X_j)\sigma(X_k)}{4} \left(\sigma \left(\frac{X_j}{\sigma(X_j)} + \frac{X_k}{\sigma(X_k)} \right)^2 - \sigma \left(\frac{X_j}{\sigma(X_j)} - \frac{X_k}{\sigma(X_k)} \right)^2 \right), \quad (4)$$

вычисляя для всех возможных пар $j, k = 1, \dots, d$.

Для $\sigma()$ в формуле (4) подставляем $\widehat{\text{MAD}}$, а $X_1, \dots, X_d$ имеют совместное эмпирическое распределение выборки $\mathbf{X}$.

Оценка (4) с $\widehat{\text{MAD}}$ устойчиво и быстро вычисляется, но **не является эквивариантной относительно вращений**.

Алгоритм 3: Устойчивая относительно вращений оценка

Скомбинируем идеи обоих алгоритмов, чтобы получить **устойчивую и эквивариантную относительно вращений и сдвигов** оценку. Будем применять случайное вращение выборки.

- 1 Рассматриваем выборку $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, задаём N — общее число шагов.
- 2 Разыграем N случайных ортогональных матриц поворота $\mathbf{Q}_i \in \mathbb{R}^{d \times d}$, $\mathbf{Q}_i$ имеет равномерное распределение в многообразии матриц $O(d)$, $i = 1, \dots, N$.
- 3 Поворачиваем выборку: $\mathbf{b}_{ik} = \mathbf{Q}_i \mathbf{x}_k$.
- 4 Находим оценку матрицы разброса выборки $\mathbf{b}_{i1}, \dots, \mathbf{b}_{in}$ с помощью формулы (4) с $\sigma() = \widehat{\text{MAD}}$, обозначим её, как $\tilde{\mathbf{S}}_i$.
- 5 Вычислим оценку матрицы $\bar{\mathbf{S}}_i$ разброса выборки $\mathbf{x}_1, \dots, \mathbf{x}_n$ на i -м шаге как $\bar{\mathbf{S}}_i = \mathbf{Q}_i^T \tilde{\mathbf{S}}_i \mathbf{Q}_i$.
- 6 В качестве финальной оценки берем $\bar{\mathbf{S}} = \frac{1}{N} \sum_{i=1}^N \bar{\mathbf{S}}_i$.

Формальная постановка задачи оценки матрицы разброса

Фактически, Алгоритм 3 даёт оценку по методу Монте-Карло для следующей величины:

$$\mathbf{S}_{\mathbf{X}} = \mathbb{E}_{\mathbf{Q}} \mathbf{Q}^T \left[\tilde{\mathbf{S}}(\mathbf{Q}\mathbf{X}) \right] \mathbf{Q},$$

где $\mathbf{Q}$ имеет равномерное распределение на многообразии ортогональных матриц $O(d)$, $\tilde{\mathbf{S}}(\mathbf{Q}\mathbf{X})$ — это оценка матрицы разброса по формуле (4) для выборки $\mathbf{X}$, к которой было применено вращение $\mathbf{Q}$.

По своему построению $\mathbf{S}_{\mathbf{X}}$ является эквивариантной относительно случайных вращений выборки. Это достигается за счет усреднения по группе вращений $O(d)$.

Сравнение методов оценки матрицы разброса

Эксперимент: 100 запусков для каждого метода на несимметричной выборке ($d = 3, n = 1000$).




Рис.: Распределение $\|\hat{S} - \Sigma\|_F$ для различных алгоритмов

❶ Получено теоретическое обоснование Алгоритма 1

- Показано, что предложенный алгоритм является методом стохастического градиента для оптимизации функционала $\varphi_{\text{амп}}$.
- Тем самым обоснована его связь с проекционной медианой и объяснены его робастные свойства.

❷ Разработаны модификации Алгоритма 1

- Предложены способы повышения устойчивости сходимости и точности оценивания.
- Экспериментально показано, что использование сглаживания, усреднения и адаптивного выбора шага позволяет уменьшить ошибку оценки.

❸ Предложен метод оценивания матрицы разброса

- Разработан алгоритм ARR-GK, сочетающий вычислительную устойчивость метода GK и эквивариантность относительно вращений.
- Экспериментально подтверждены его состоятельность и робастность.