

Алгоритмы извлечения сигнала из временных рядов с использованием метода Monte Carlo SSA

Потешкин Егор Павлович, гр.24.M22-мм

Санкт-Петербургский государственный университет
Математическое моделирование, программирование и искусственный интеллект

Кафедра статистического моделирования

Научный руководитель — д. ф.-м. н. Н. Э. Голяндина
Рецензент — старший разработчик И. С. Лунев, ООО «Автономный транспорт»

Санкт-Петербург, 2026

$X = (x_1, \dots, x_N)$ — временной ряд длины N .

Модель: $X = T + P + R$, где T — тренд, P — периодическая компонента и R — шум, случайная составляющая.

Проблема: Как автоматически выделить сигнал $S = T + P$?

Метод: Singular spectrum analysis (SSA) [Broomhead and King, 1986; Golyandina, Nekrutkin and Zhigljavsky, 2001].

Преимущества:

- 1 Не требует задания модели сигнала и шума, в частности, периодов цикличности.
- 2 Позволяет строить прогноз и заполнять пропуски.

Проблема: один из шагов SSA требует визуального анализа для определения сигнальных компонент, необходима автоматизация этого шага.

Входные данные: временной ряд $X = (x_1, \dots, x_N)$.

Параметр: длина окна L , $1 < L < N$.

Результат: разложение $X = \hat{T} + \hat{P} + \hat{R}$.

- ❶ **Вложение:** $X = \mathcal{T}(X) = [X_1 : \dots : X_K]$, где $X_i = (x_1, \dots, x_{i+L-1})^T$, $K = N - L + 1$.
- ❷ **Разложение:** $X = \sum_{i=1}^d \sigma_i P_i Q_i^T = X_1 + \dots + X_d$, $\text{rank } X_i = 1$.
В базовом SSA используется сигнулярное разложение (SVD).
- ❸ **Восстановление:** $X = \sum_{i=1}^d X^{(j)}$, где $X^{(j)} = \mathcal{T}^{-1} \circ \mathcal{H}(X_j)$ — элементарные восстановленные компоненты.
- ❹ **Идентификация компонент:** Выбор множеств $J_{\text{Periodics}}$, $J_{\text{Trend}} \subset \{1, \dots, d\}$ индексов компонент, соответствующих тренду и периодикам.
- ❺ **Группировка:** $\hat{T} = \sum_{j \in J_{\text{Trend}}} X^{(j)}$, $\hat{P} = \sum_{j \in J_{\text{Periodics}}} X^{(j)}$, $\hat{R} = X - \hat{T} - \hat{P}$.

Как определить J_{Trend} и $J_{\text{Periodics}}$?

Тренд $T = (t_1, \dots, t_N)$ будем определять как низкочастотную компоненту.

Периодическая компонента $P = (p_1, \dots, p_N)$ состоит из экспоненциально-модулированных (э-м) гармоник:

$$p_n = \sum_{i=1}^m A_i e^{a_i n} \cos(2\pi\omega_i n) \quad i = 1, \dots, N.$$

Будем характеризовать тренд и периодики частотным способом, для этого подходит периодограмма:

$$\Pi(k/N) = \frac{N}{2} \begin{cases} 2C_0^2 & \text{для } k = 0, \\ C_k^2 + S_k^2 & \text{для } 0 \leq k \leq N/2, \\ 2C_{N/2}^2 & \text{для } k = N/2, \text{ если } N \text{ четное.} \end{cases}$$


где коэффициенты C_k и S_k взяты из разложения Фурье ряда X :

$$x_n = C_0 + \sum_{k=1}^{\lfloor (N-1)/2 \rfloor} \sqrt{C_k^2 + S_k^2} \cos(2\pi nk/N + \phi_k) + C_{N/2} \cdot (-1)^n.$$

Периодограмма: пример

Сигнал $s_n = t_n + p_n$ — сумма линейного тренда и э-м гармоник:

$$t_n = 0.05n, \quad p_n = 0.1e^{0.02n} \cos(2\pi n/8) + 1.5 \cos(2\pi n/3), \quad n = 1, \dots, 200.$$



Выделить тренд можно, взяв компоненты разложения $X^{(j)}$, у которых преобладают низкие частоты периодограммы.

Проблема: для периодической компоненты данный подход усложнен тем, что ее **частоты колебания неизвестны**.

Под шумом подразумевается стационарный в широком смысле процесс $\xi = (\xi_1, \dots, \xi_n, \dots)$ с нулевым средним.

В данной работе рассматриваются следующие модели шума:

- Белый гауссовский шум с дисперсией σ^2 : $\varepsilon_t \sim N(0, \sigma^2)$.
- Красный шум (AR(1)) с параметрами $\phi > 0$ и σ^2 :


$$\xi_t = (1 - \phi B)^{-1} \varepsilon_t,$$

где B — оператор сдвига.


- Шум с длинной памятью (ARFIMA(0, d , 0)):

$$\xi_t = (1 - B)^{-d} \varepsilon_t, \quad d < 1/2.$$

Модели шума: спектральная плотность и АСФ



(a) Спектральная плотность



(b) Автокорреляционная функция

Обозначения и известные результаты: Multiple Monte Carlo SSA [Golyandina, 2023]

Модель: $X = P + \xi$, где $P = S - T$ соответствует неизвестным частотам, ξ — шум.

Задача: проверить $H_0 : P = 0$ — отсутствие сигнала.

Метод: Multiple Monte Carlo SSA [Golyandina, 2023] (далее просто MC-SSA).

Параметры: длина окна L , выбор векторов $W_1, \dots, W_M \in \mathbb{R}^L$, модель шума ξ , уровень значимости α , количество суррогатных реализаций G .


- 1 Вычислить статистики критерия $\hat{p}_k = \|\mathbf{X}^T W_k\|^2$, $k = 1, \dots, M$.
- 2 Оценить параметры шума ξ по ряду X .
- 3 Построить эмпирическое распределение $(1 - \alpha)$ -квантиля максимума стандартизованных статистик на основе G суррогатных реализаций ξ .
- 4 Построить предсказательные интервалы с поправкой на множественные сравнения с уровнем доверия $(1 - \alpha)$.

MC-SSA: пример

Модель: $x_n = p_n + \xi_n$, где $\{\xi_n\}$ — красный шум с $\phi = 0.7$ и $\sigma^2 = 1$, $N = 200$,

$$p_n = 0.075e^{0.02n} \cos(2\pi n/8) + 1.2 \cos(2\pi n/4) + 0.25 \cdot (-1)^n.$$

Результат MC-SSA для $L = 48$, $W_k = \{\cos(2\pi kn/(2L))\}_{n=1}^L$, $k = 1, \dots, L$:



MC-SSA применяется к $X - \hat{T} \Rightarrow$ доверять низким частотам периодограммы нельзя.

Решение: предложена модификация метода Уиттла оценки параметров θ по части спектра с частотами из $\mathcal{B}$.

Максимизируется аппроксимация логарифма правдоподобия:

$$\ell_{W_{\text{part}}}(\theta; \mathcal{B}) = -\frac{1}{|J_{\mathcal{B}}|} \sum_{j \in J_{\mathcal{B}}} \left(\ln f_{\xi}(j/N; \theta) + \frac{\Pi(j/N)}{f_{\xi}(j/N; \theta)} \right),$$

где θ — вектор параметров шума ξ , f_{ξ} — спектральная плотность шума ξ , $\Pi(j/N)$ — периодограмма,
 $J_{\mathcal{B}} = \{j \in \{1, \dots, m\} : \omega_j = j/N \in \mathcal{B}\}$, $m = \lfloor (N-1)/2 \rfloor$.

Как идентифицировать компоненты по интервалу частот?

Для компонент $X^{(j)}$ из разложения $X = \sum_j X^{(j)}$, и $0 \leq \omega_1 \leq \omega_2 \leq 0.5$ определим меру

$$T(X^{(j)}; \langle \omega_1, \omega_2 \rangle) = \frac{1}{\|X^{(j)}\|^2} \sum_{k: k/N \in \langle \omega_1, \omega_2 \rangle} \Pi(k/N).$$

где $\Pi(k/N)$ — периодограмма ряда $X^{(j)}$.

Величину $T(X^{(j)}; \langle \omega_1, \omega_2 \rangle) \in [0, 1]$ можно рассматривать как долю вклада частот, содержащегося в интервале $\langle \omega_1, \omega_2 \rangle$.

Замечание (идентификация трендовых компонент)

$$J_{\text{Trend}} = \left\{ j : T(X^{(j)}; [0, \omega_0]) > T_0 \right\},$$

где T_0 — порог вклада низких частот [Александров, Голяндина, 2004].

Идентификация э-м гармоник по заданной частоте: алгоритм

Дано: разложение $X = \sum_{j \in J} X^{(j)} + \dots$, где J — множество индексов, среди которых ищутся э-м гармонические компоненты.

Параметры: частота ω^* , радиус частотного интервала $\delta > 0$, порог $P_0 \in [0, 1]$.

Задача: получить оценку гармоники $\hat{H}$, соответствующей частоте ω^* .

- ❶ Для каждой компоненты $X^{(j)}$ вычислить меру $T_j = T(X^{(j)}; [\omega^* - \delta, \omega^* + \delta])$.
- ❷ Определить компоненты $J_{\omega^*} = \{j \in J : T_j > P_0\}$.
- ❸ Выбрать из множества J_{ω^*} первые $r_{\omega^*} \in \{1, 2\}$ компонент по вкладу и составить из них множество J_{Harmonic} .
- ❹ Вычислить оценку гармоники $\hat{H} = \sum_{j \in J_{\text{Harmonic}}} X^{(j)}$.

Обозначения и известные результаты: Метод SSA-Aid [Дудник, 2025]

Входные данные: временной ряд X , длина окна L_{SSA} , максимальная оценка ранга сигнала $r_{\max}$.

Результат: оценка тренда $\hat{T}$, начальная оценка периодик $\tilde{P}$ и разложение

$$X = \sum_{j=1}^{\hat{r}} X^{(j)} + \sum_{j=\hat{r}+1}^{r_{\max}} X^{(j)} + \hat{R},$$

где $\sum_{j=1}^{\hat{r}} X^{(j)} = \hat{T} + \tilde{P}$ — оценка сигнала.

Допущение: сигналу соответствуют первые компоненты разложения.

Проблема: при неравномерном спектре шума сигнальные компоненты могут оказаться в $\sum_{j=\hat{r}+1}^{r_{\max}} X^{(j)}$.


SSA-AidMC является расширением метода SSA-Aid, который:

- 1 модифицирует этап отбора периодик с помощью идентификация э-м гармоник по заданной частоте;
- 2 с помощью критерия MC-SSA находит оставшиеся в $\sum_{j=\hat{r}+1}^{r_{\max}} X^{(j)}$ периодические компоненты.

Параметры SSA-AidMC:

- длины окна L_{SSA} и максимальная оценка ранга сигнала $r_{\max}$ для метода SSA;
- порог низких частот ω_0 и порог T_0 для идентификации трендовых компонент;
- длина окна L_{MC-SSA} , модель шума ξ и уровень значимости α для метода MC-SSA;
- частотный радиус δ и порог P_0 для идентификации э-м гармоник по заданной частоте.

Метод SSA-AidMC: блок-схема алгоритма



Модель: $X = T + P + R$, где $N = 200$, $T = (t_1, \dots, t_N)$ — тренд, $P = (p_1, \dots, p_N)$ — периодика, R — реализация шума ξ .

Задача: сравнить разработанный метод SSA-AidMC с SSA-Aid и с классическими методами: STL, ETS, SARIMA.

Методы сравнивались в следующих задачах:

- 1 **восстановление** сигнала, **декомпозиция** сигнала на тренд и периодику;
- 2 **прогнозирование** ряда на разные горизонты.

Рассмотрены следующие группы сигналов:

- 1 сигнал **доминирует** над шумом по вкладу;
- 2 некоторые компоненты сигнала **не доминируют** по вкладу над шумовыми.

Численное сравнение SSA-AidMC с другими методами: примеры

Примеры сигналов, доминирующих над шумом:

- 1 сложный нелинейный тренд, периодическая компонента с постоянной амплитудой;
- 2 сложный нелинейный тренд, m -периодическая компонента.

Примеры сигналов, не доминирующих над шумом:

- 1 линейный тренд, периодическая компонента с постоянной амплитудой;
- 2 линейный тренд, m -периодическая компонента.

Модели шума ξ : белый шум (только для доминирующего сигнала) с $\sigma^2 = 1$, красный шум и шум с длинной памятью.

Численное сравнение SSA-AidMC с другими методами: MSE восстановление сигнала

Пример 4: линейный тренд, э-м периодическая компонента

$$t_n = 0.05n, \quad p_n = 0.075e^{0.02n} \cos\left(\frac{2\pi n}{8}\right) + 1.5e^{-0.01n} \cos\left(\frac{2\pi n}{4}\right) + e^{-0.01n} \cdot (-1)^n$$

Компонента	Метод	AR(1), $\phi = 0.7$		ARFIMA(0, 0.4, 0)	
		Mean	Median	Mean	Median
Тренд	SSA-Aid	0.7978	0.7773	1.2896	1.1208
	SSA-AidMC	0.7667	0.7524	1.2866	1.0889
	ETS	1.9884	1.9782	1.7448	1.4184
	STL	0.8538	0.8427	1.3114	1.1131
Периодика	SSA-Aid	0.4578	0.3332	0.1411	0.0729
	SSA-AidMC	0.1137	0.0926	0.0779	0.0701
	ETS	0.4943	0.4560	0.7367	0.6679
	STL	0.2094	0.2031	0.1869	0.1828
Сигнал	SSA-Aid	1.2215	1.1766	1.4236	1.2404
	SSA-AidMC	0.8633	0.7975	1.3582	1.1499
	ETS	1.9336	1.9845	1.7108	1.4719
	STL	1.0532	1.0525	1.4920	1.2678

Численное сравнение SSA-AidMC с другими методами: гибридный подход к прогнозированию

SSA:

- хорошо прогнозирует периодику;
- в случае цветного шума прогноз тренда может быть неустойчив;

ETS:

- более простая модель тренда дает более устойчивый прогноз;
- грубый прогноз периодики по последнему периоду.

Гибридный подход к прогнозированию:

- 1 прогноз периодической компоненты осуществляется с помощью SSA;
- 2 прогноз тренда строится с помощью ETS по ряду с вычтенной оценкой периодик.

Численное сравнение SSA-AidMC с другими методами: среднее MSE прогноза

Пример 4: линейный тренд, э-м периодическая компонента

$$t_n = 0.05n, \quad p_n = 0.075e^{0.02n} \cos\left(\frac{2\pi n}{8}\right) + 1.5e^{-0.01n} \cos\left(\frac{2\pi n}{4}\right) + e^{-0.01n} \cdot (-1)^n$$

Метод	AR(1), $\phi = 0.7$		ARFIMA(0, 0.4, 0)	
	Одна точка	Один период	Одна точка	Один период
SSA-Aid	2.4354	6.1870	2.1195	3.3039
SSA-Aid+ETS	1.9349	5.4043	1.6584	2.1020
SSA-AidMC	2.2051	4.3720	2.0471	2.8696
SSA-AidMC+ETS	1.6646	3.3779	1.6156	1.8511
SARIMA	1.5468	3.9603	1.8258	2.8356
ETS	2.2713	6.5158	3.1392	3.0563
STL	1.7200	4.1858	2.0645	2.9496

- ❶ Разработан алгоритм SSA-AidMC — метод автоматической идентификации компонент в SSA, основанный на критерии MC-SSA.
- ❷ Для построения алгоритма SSA-AidMC был решен ряд задач, связанных с применением MC-SSA на практике:
 - проведено исследование зависимости мощности критерия от длины окна;
 - метод MC-SSA обобщен на временные ряды с длинной памятью;
 - предложена модификация MC-SSA по части спектра, исключая выбранные частоты из рассмотрения как при оценке параметров шума, так и при проверке гипотезы.
- ❸ Для разработанного метода предложены рекомендации к выбору его параметров.
- ❹ Метод сравнен с другими методами декомпозиции и прогнозирования; по результатам численного сравнения установлено, что метод является конкурентоспособным с классическими методами, в некоторых случаях превосходя их.