

# Модели сложных распределений с приложением в радиобиологии

Олейник Михаил Владимирович, гр.24.M04-мм

Санкт-Петербургский государственный университет  
Прикладная математика и информатика  
Вычислительная стохастика и статистические модели

Научный руководитель: к. ф.-м. н., доцент Алексеева Н. П.  
Рецензент: Зав. отделом биомедицинской статистики, ПСПбГМУ,  
к. б. н., доцент Вербицкая Е. В.

Санкт-Петербург, 2026

Идейно является продолжением бакалаврской работы [Олейник, 2024].

**Прикладной контекст:**

- Радиобиология (моделирование радиационно-индуцированных повреждений) [Алексеева, 2008,2013];
- Модели клеточной выживаемости;
- Модели типа Neyman'a [Neyman, 1976; Ainsbury, 2013];
- Анализ стохастических каскадов событий.

**Математическая проблема:**

- Наблюдаем взаимодействие двух распределений с суммарным эффектом;
- Элементарное распределение (механизм повреждений) неизвестно;
- Требуется восстановить исходные вероятности.

**Цель работы:** Продолжение изучения классов сложных распределений и построение устойчивых алгоритмов обращения сложных распределений с демонстрацией применения в радиобиологии.

**Сложное распределение** (compound distribution) — случайная сумма:

$$S = X_1 + \dots + X_\tau,$$

где:

- $X_i$  — независимые одинаково распределённые случайные величины (внутреннее распределение);
- $\tau$  — случайная величина, не зависящая от  $X_i, \forall i \geq 1$  (число воздействий или внешнее распределение).

Обозначим для удобства:

$$P(s) = P(X_i = s), \quad F(s) = P(\tau = s), \quad R(s) = P(S = s).$$

**Прямая задача** состоит в построении распределения  $R$  по распределениям  $P$  и  $F$ ;

**Обратная задача:** из распределений  $R$  и  $F$  найти  $P$ .

Введём производящие функции [Феллер, 1952]:

$$G_P(t) = \sum_{s=0}^{\infty} P(s)t^s; \quad G_F(t) = \sum_{s=0}^{\infty} F(s)t^s; \quad G_R(t) = \sum_{s=0}^{\infty} R(s)t^s.$$

Тогда для случайной суммы:

$$G_R(t) = G_F(G_P(t)).$$

Производящие функции являются хорошим инструментом для анализа сложных распределений, однако прямое обращение:

$$G_P(t) = G_F^{-1}(G_R(t)),$$

затруднительно по ряду причин (в том числе, мы не знаем точные функции для экспериментальных данных).

Рассмотрим ряд сложных распределений, применяемых в работе:

- **ЛПР**:  $\tau \sim \text{Log}(q_1)$ ,  $X_i \sim \text{Pois}(\lambda) \implies S \sim \text{LogPois}(q_1, \lambda)$   
(логарифмически-пуассоновское распределение).

Производящая функция:  $G_R(t) = -\alpha_1 (1 - q_1 e^{\lambda(t-1)})$ , где  $\alpha_i = -1/\ln(1 - q_i)$ ,  $i = 1, 2$ .

Вероятности через числа Стирлинга второго рода и Эйлера первого рода найдены в бакалаврской работе.

- **ЛБР**:  $\tau \sim \text{Log}(q_1)$ ,  $X_i \sim \text{Bin}(n_1, p_1) \implies S \sim \text{LogBin}(q_1, n_1, p_1)$   
(логарифмически-биномиальное распределение).

Производящая функция:  $G_R(t) = -\alpha_1 \ln(1 - q_1(p_1 t + 1 - p_1)^{n_1})$ .

- **БЛР**:  $\tau \sim \text{Bin}(n_2, p_2)$ ,  $X_i \sim \text{Log}(q_2) \implies S \sim \text{BinLog}(n_2, p_2, q_2)$   
(биномиально-логарифмическое распределение).

Производящая функция:  $G_R(t) = (-p_2 \alpha_2 \ln(1 - q_2 t) + 1 - p_2)^{n_2}$ .

Вероятности через числа Стирлинга первого рода найдены в бакалаврской работе.

Используя свойство производящих функций [Феллер, 1952]:

$$P(\eta = k) = \frac{G^{(k)}(0)}{k!},$$

могут быть найдены вероятности ЛБР.

## Теорема

*Вероятности ЛБР задаются следующими формулами. Для  $k = 0$ :*

$$P(S_\tau = 0) = -\alpha \ln(1 - q(1 - p)^n), \quad (1)$$

*а для  $k = 1, 2, \dots$ :*

$$P(S_\tau = k) = \frac{1}{k!} \alpha p^k \sum_{j=1}^k q^j n^j U_n(k, j) \frac{(1 - p)^{j(n-k)}}{(1 - q(1 - p)^n)^j}, \quad (2)$$

*где  $\alpha = \frac{-1}{\ln(1-q)}$ ,  $U_n(k, j)$  — числа, зависящие от  $n$  и имеющие рекуррентную формулу.*

# Числа $U_n$

Числа  $U_n$  похожи на числа Стирлинга

$$(I) : s(k+1, j) = s(k, j-1) + k \cdot s(k, j)$$

$$(II) : S(k+1, j) = S(k, j-1) + j \cdot S(k, j)$$

и Эйлера

$$(I) : e(k+1, j) = (k-j+1) \cdot e(k, j-1) + (j+1) \cdot e(k, j)$$

$$(II) : E(k+1, j) = (2k-j+1) \cdot E(k, j-1) + (j+1) \cdot E(k, j)$$

однако зависят от  $n$  (параметр бинома) и имеют немного другие коэффициенты в рекуррентной формуле:

$$U_n(k+1, j) = (j-1) \cdot U_n(k, j-1) + (jn-k) \cdot U_n(k, j), 1 \leq j \leq k+1,$$

$$U_n(1, 1) = 1, U_n(k, 0) = 0 \text{ при } k > 0, U_n(0, j) = 0 \text{ при } j > 0.$$

| $k \setminus j$ | 1                     | 2                      | 3                 | 4          | 5  |
|-----------------|-----------------------|------------------------|-------------------|------------|----|
| 1               | 1                     |                        |                   |            |    |
| 2               | $n_{-1}$              | 1                      |                   |            |    |
| 3               | $n_{-1}n_{-2}$        | $3n_{-1}$              | 2                 |            |    |
| 4               | $n_{-1} \dots n_{-3}$ | $n_{-1}(7n-11)$        | $12n_{-1}$        | 6          |    |
| 5               | $n_{-1} \dots n_{-4}$ | $n_{-1}n_{-2}(15n-25)$ | $2n_{-1}(25n-35)$ | $60n_{-1}$ | 24 |

где  $n_{-i} = n - i$ .

# Эквивалентность ЛБР и БЛР при $n = 1$ : ЛББЛ

## Теорема

Распределения  $\text{LogBin}(q_1, 1, p_1)$  и  $\text{BinLog}(1, p_2, q_2)$  совпадают.  
Параметры связаны:

$$q_1 = 1 - (1 - q_2)^{1/p_2}, \quad p_1 = q_2 (1 - q_2)^{(1-p_2)/p_2} / q_1,$$

или

$$q_2 = \frac{p_1 q_1}{p_1 q_1 + 1 - q_1}, \quad p_2 = \frac{\ln(1 - q_2)}{\ln(1 - q_1)}.$$

## Утверждение


Вероятности ЛББЛ при  $k = 0$  равны

$P(S_\tau = 0) = -\alpha \ln(1 - q_1(1 - p_1)) = 1 - p_2$ ; при  $k = 1, 2, \dots$ :

$$P(S_\tau = k) = \frac{1}{k} \frac{\alpha_1 q_1^k p_1^k}{(1 - q_1(1 - p_1))^k} = \frac{1}{k} \alpha_2 q_2^k p_2.$$

ЛББЛ — двухпараметрическое распределение, **независимо** возникающее из двух трёхпараметрических семейств.

Исследована связь рассматриваемых распределений:



Классы БЛР и ЛБР сильно пересекаются и обладают синонимичностью (для многих параметров ЛБР можно найти параметры БЛР, для которых есть согласие), однако не совпадают, как по предельным случаям, так и по некоторым наборам параметров.

**Задача обращения:** в эксперименте наблюдаются эмпирические распределения суммы  $S$  и внешнего распределения  $\tau$ . Нужно определить внутреннее распределение  $X_i$ .

**Более формально:** из двух случайных величин можно получить третью с помощью некоторого оператора:

$$T(P, F) = R,$$

где  $R$  — распределение  $S$ ,  $F$  —  $\tau$ , а  $P$  —  $X_i$ .

Введём **оператор обращения**:

$$T'(R, F) = P.$$

Оператор  $T$  может быть и оператором сложения двух распределений (свёртка).

Для сложения были получены формулы обращения, однако модель оказалась неприменима к радиобиологическим данным.

## Утверждение

Для сложного распределения  $S_\tau = X_1 + \dots + X_\tau$  справедлива рекуррентная формула обращения:

$$P(s) = \frac{R(s) - \sum_{k=0}^{\infty} F(k) \sum_{\substack{i_1 + \dots + i_k = s \\ i_j \neq s}} P(i_1) \dots P(i_k)}{\sum_{k=0}^{\infty} F(k) \cdot k \cdot (P(0))^{k-1}}. \quad (3)$$

$P(0)$  находится из уравнения  $R(0) = \sum_{k=0}^{\infty} F(k) \cdot (P(0))^k$ .

**Проблема:** задача некорректна по Адамару:

- Малые возмущения  $R$  приводят к большим изменениям  $P$ ;
- Чувствительность возрастает с ростом  $s$ ;
- Возможны отрицательные вероятности при численном обращении.

# Оптимизация формулы обращения и корректировка

- Несмотря на наличие бесконечных сумм, в реальности мы имеем дело с ограниченным числом вероятностей ( $\sum_{k=0}^{\infty} \rightarrow \sum_{k=0}^m$ , где  $m$  — максимум из наблюдаемых значений  $S_{\tau}$  и  $\tau$ ).

## Утверждение

*Для компьютерных вычислений найдена оптимизированная запись, где внутренняя сумма заменена на:*

$$\sum_{\substack{j_1 \cdot (s-1) + j_2 \cdot (s-2) + \\ + \dots + j_s \cdot 0 = s \\ j_1 + j_2 + \dots + j_s = k}} \frac{k!}{j_1! j_2! \dots j_s!} (P(s-1))^{j_1} \cdot (P(s-2))^{j_2} \dots (P(0))^{j_s},$$

*где  $j_s$  — дополнение ненулевых слагаемых до цепочки длины  $k$ .*

Для решения проблемы отрицательных вероятностей введём **эвристическую корректировку**: получая отрицательные вероятности будем «поднимать» вероятности на модуль этой вероятности, а если сумма превышает 1, то будем нормировать.

# Минимизационная задача

Рассмотрим ещё один метод нахождения внутренних вероятностей — решение **минимизационной задачи**.

Пусть оператор  $T$  образует сложное распределение из простых:

$$T(P, F)(s) = \sum_{k=0}^{\infty} F(k) \cdot \sum_{i_1 + \dots + i_k = s} P(i_1) \cdots P(i_k),$$

а  $\text{diff } P = \sum_{s=1}^k (P(s) - P(s-1))^2$  — сглаживающий оператор.

Тогда задачу обращения можно записать в виде:

$$\begin{cases} (\|T(P, F) - R\|^2 + \lambda \text{diff } P) \rightarrow \min_P \\ \text{при условии } P(s) \geq 0 \ \forall s, \sum_{s=0}^{\infty} P(s) = 1 \end{cases}$$

# Пример: сложно-геометрическое распределение

- Применим методы для модельных данных.
- Смоделируем сложно-геометрическое распределение:  
 $\tau \sim \text{Geom}(p_1), p_1 = 0.5$  и  $X_i \sim \text{Geom}(p_2), p_2 = 0.5$ . Размер выборки: 1000.






Рис.: Без корректировки

Рис.: С корректировкой

Рис.: Минимизация

Визуально видно, что алгоритмы работают, однако важно проверить сходимость и порядок отклонений.

Сходимость по  $L_2$  норме ( $\|\hat{P} - P\|_2$ ) для разных наборов  $p_1$  и  $p_2$ :

Рис.: без коррективки




Рис.: с коррективкой








Рис.: минимизация



Сходимость по  $KL$ -дивергенции ( $D_{KL}(\hat{P} \| P)$ ) для разных наборов  $p_1$  и  $p_2$ :



# Смещение по вероятностям

- Корректировка помогает избежать отрицательных вероятностей, однако может вносить смещение в итоговое распределение.
- На сложно-геометрическом примере показано, что смещение может быть заметным, особенно для больших  $s$ , где вероятности уже малы и чувствительность выше.

$$\text{relative\_bias}(s) = E|\hat{P}(s) - P(s)|/P(s),$$




Рис.: без корректировки




Рис.: с корректировкой




Рис.: минимизация

Прикладная задача — распределения в радиобиологии.

- В работе [Алексеева, 2008] и книге [Алексеева, 2013] в качестве модели для клеточных аномалий, возникающих при облучении, было предложено реинтрантно-биномиальное распределение.
- В бакалаврской работе рассматривались три модели: ЛПР, БЛР и ЛБР.

| Доза, Гр | in vitro |    |    |    |   |          | in vivo |    |    |    |    |          |
|----------|----------|----|----|----|---|----------|---------|----|----|----|----|----------|
|          | 0        | 1  | 2  | 3  | 4 | $\geq 5$ | 0       | 1  | 2  | 3  | 4  | $\geq 5$ |
| 0        | 68       | 25 | 7  |    |   |          | 66      | 31 | 2  | 1  |    |          |
| 5        | 74       | 19 | 5  | 2  |   |          | 50      | 35 | 13 | 2  |    |          |
| 10       | 59       | 24 | 16 | 1  |   |          | 41      | 39 | 17 | 2  | 1  |          |
| 15       | 48       | 33 | 11 | 3  | 2 | 3        | 27      | 39 | 29 | 3  | 1  | 1        |
| 20       | 59       | 31 | 5  | 4  | 1 |          | 22      | 22 | 32 | 15 | 6  | 3        |
| 25       | 37       | 31 | 22 | 6  | 2 | 2        | 33      | 39 | 18 | 8  | 1  | 1        |
| 30       | 35       | 37 | 17 | 5  | 3 | 3        | 21      | 29 | 21 | 14 | 10 | 5        |
| 35       | 26       | 36 | 19 | 10 | 5 | 4        | 17      | 24 | 32 | 11 | 10 | 6        |
| 40       | 19       | 33 | 25 | 11 | 7 | 5        | 15      | 17 | 29 | 18 | 11 | 10       |
| 45       |          |    |    |    |   |          | 13      | 14 | 24 | 24 | 12 | 13       |

# Обращение для радиобиологических данных

По логике эксперимента: **in vivo** — внешнее ( $\tau$ ), **in vitro** — сложное распределение ( $S$ ).

**Задача:** найти **внутреннее** распределение ( $X_i$ ).













Рис.: Модель радиобиологических данных

# Вероятности внутреннего распределения ( $X_i$ )

| Гр | Алгоритм | $P(0)$ | $P(1)$       | $P(2)$        | $P(3)$        | $P(4)$        | $P(\geq 5)$   |
|----|----------|--------|--------------|---------------|---------------|---------------|---------------|
| 0  | Без      | 0.064  | 0.799        | 0.179         | <b>-0.036</b> | <b>-0.009</b> | 0.002         |
|    | Кор.     | 0.095  | 0.695        | 0.189         | 0.015         | 0.004         | 0.001         |
|    | Мин.     | 0.121  | 0.676        | 0.202         | 0.000         | 0.000         | 0.000         |
| 5  | Без      | 0.559  | 0.369        | 0.054         | 0.024         | <b>-0.007</b> | 0.000         |
|    | Кор.     | 0.542  | 0.361        | 0.061         | 0.032         | 0.002         | 0.001         |
|    | Мин.     | 0.552  | 0.363        | 0.064         | 0.020         | 0.000         | 0.000         |
| 10 | Без      | 0.391  | 0.449        | 0.223         | <b>-0.063</b> | <b>-0.007</b> | 0.009         |
|    | Кор.     | 0.340  | 0.379        | 0.226         | 0.037         | 0.014         | 0.005         |
|    | Мин.     | 0.385  | 0.423        | 0.193         | 0.000         | 0.000         | 0.000         |
| 15 | Без      | 0.408  | 0.511        | 0.031         | 0.016         | 0.016         | 0.035         |
|    | Кор.     | 0.375  | 0.465        | 0.046         | 0.033         | 0.032         | 0.049         |
|    | Мин.     | 0.414  | 0.487        | 0.048         | 0.007         | 0.017         | 0.028         |
| 20 | Без      | 0.688  | 0.315        | <b>-0.039</b> | 0.049         | <b>-0.015</b> | 0.006         |
|    | Кор.     | 0.633  | 0.314        | 0.011         | 0.034         | 0.006         | 0.002         |
|    | Мин.     | 0.685  | 0.294        | 0.000         | 0.020         | 0.000         | 0.000         |
| 25 | Без      | 0.098  | 0.725        | 0.264         | <b>-0.118</b> | 0.003         | 0.063         |
|    | Кор.     | 0.155  | 0.500        | 0.246         | 0.058         | 0.022         | 0.019         |
|    | Мин.     | 0.146  | 0.627        | 0.227         | 0.000         | 0.000         | 0.000         |
| 30 | Без      | 0.359  | 0.714        | <b>-0.126</b> | 0.013         | 0.062         | <b>-0.005</b> |
|    | Кор.     | 0.322  | 0.488        | 0.093         | 0.045         | 0.023         | 0.030         |
|    | Мин.     | 0.409  | 0.574        | 0.000         | 0.000         | 0.014         | 0.002         |
| 35 | Без      | 0.268  | 0.810        | <b>-0.256</b> | 0.346         | <b>-0.420</b> | 0.664         |
|    | Кор.     | 0.261  | 0.475        | 0.054         | 0.065         | 0.056         | 0.088         |
|    | Мин.     | 0.343  | 0.615        | 0.005         | 0.024         | 0.013         | 0.000         |
| 40 | Без      | 0.176  | <b>1.131</b> | <b>-0.946</b> | <b>1.962</b>  | <b>-4.796</b> | <b>13.323</b> |
|    | Кор.     | 0.251  | 0.380        | 0.100         | 0.078         | 0.091         | 0.101         |
|    | Мин.     | 0.326  | 0.649        | 0.000         | 0.000         | 0.025         | 0.000         |

## Восстановление вероятностей (по оператору $T$ )



# Параметризация внутреннего распределения: ЛПР

**Вопрос:** каким распределением можно параметризовать полученные вероятности?

Таблица: С корректировкой

| Гр | $\lambda$ | $q$  | p-v          | $\chi^2$     |
|----|-----------|------|--------------|--------------|
| 0  | 1.1       | 4e-8 | <b>3e-13</b> | <b>52.92</b> |
| 5  | 0.58      | 7e-7 | -            | <b>0.79</b>  |
| 10 | 0.97      | 1e-6 | <b>0.14</b>  | <b>2.21</b>  |
| 15 | 0.53      | 0.70 | <b>1e-4</b>  | <b>17.96</b> |
| 20 | 0.36      | 0.28 | -            | <b>1.44</b>  |
| 25 | 1.3       | 6e-8 | <b>4e-4</b>  | <b>12.50</b> |
| 30 | 0.75      | 0.47 | <b>8e-4</b>  | <b>11.25</b> |
| 35 | 0.68      | 0.77 | <b>3e-5</b>  | <b>21.18</b> |
| 40 | 0.74      | 0.81 | <b>0.02</b>  | <b>9.57</b>  |

Таблица: Минимизационная задача

| Гр | $\lambda$ | $q$  | p-v          | $\chi^2$     |
|----|-----------|------|--------------|--------------|
| 0  | 1.1       | 6e-8 | <b>2e-12</b> | <b>49.74</b> |
| 5  | 0.55      | 2e-9 | -            | <b>1.23</b>  |
| 10 | 0.81      | 9e-8 | -            | <b>1.93</b>  |
| 15 | 0.57      | 0.40 | <b>2e-4</b>  | <b>13.86</b> |
| 20 | 0.33      | 6e-6 | -            | <b>0.65</b>  |
| 25 | 1.1       | 3e-8 | <b>3e-10</b> | <b>39.39</b> |
| 30 | 0.62      | 2e-6 | -            | <b>30.01</b> |
| 35 | 0.67      | 4e-6 | -            | <b>34.60</b> |
| 40 | 0.75      | 1e-6 | -            | <b>41.90</b> |

Судя по p-value и статистике  $\chi^2$ , модель ЛПР не очень подходит для данных.

# Параметризация внутреннего распределения: ЛББЛ

Оценки параметров и значимости критерия хи-квадрат:

Таблица: С коррективкой










| Гр | $q$  | $p$  | $p-v$       | $\chi^2$     |
|----|------|------|-------------|--------------|
| 0  | 0.35 | 0.89 | -           | <b>2.04</b>  |
| 5  | 0.63 | 0.33 | -           | <b>0.06</b>  |
| 10 | 0.68 | 0.52 | <b>1e-3</b> | <b>10.70</b> |
| 15 | 0.78 | 0.44 | <b>0.01</b> | <b>6.15</b>  |
| 20 | 0.63 | 0.25 | -           | <b>0.08</b>  |
| 25 | 0.62 | 0.77 | <b>0.02</b> | <b>5.46</b>  |
| 30 | 0.72 | 0.53 | <b>0.24</b> | <b>1.40</b>  |
| 35 | 0.84 | 0.54 | <b>0.01</b> | <b>8.73</b>  |
| 40 | 0.90 | 0.50 | <b>0.34</b> | <b>2.18</b>  |

Таблица: Минимизационная задача

| Гр | $q$  | $p$  | $p-v$ | $\chi^2$    |
|----|------|------|-------|-------------|
| 0  | 0.37 | 0.85 | -     | <b>1.77</b> |
| 5  | 0.59 | 0.34 | -     | <b>0.06</b> |
| 10 | 0.57 | 0.51 | -     | <b>3.08</b> |
| 15 | 0.58 | 0.47 | -     | <b>0.66</b> |
| 20 | 0.34 | 0.26 | -     | <b>0.04</b> |
| 25 | 0.41 | 0.82 | -     | <b>2.83</b> |
| 30 | 0.16 | 0.57 | -     | <b>6e-4</b> |
| 35 | 0.27 | 0.62 | -     | <b>0.76</b> |
| 40 | 0.22 | 0.65 | -     | <b>1.76</b> |

Применение  $\chi^2$  ограничено из-за малого объема выборки, высокой скученности распределений и наличию 2-х параметров  
( $df = (\leq 6[\text{вероятностей}]) - 2[\text{параметра}] - 1 \leq 3$ ).

# Вероятности модели ЛББЛ






Рис.: Динамика средних компонент ЛБЛ

**Предположение:** Количество аномалий зависит от облучения по логарифму, а возникновение аномалий при делении — от бинома.

- Продолжено исследование сложных распределений:
  - Найдена точная формула вероятностей ЛБР;
  - Исследованы связи рассматриваемых сложных распределений (общий частный случай ЛББЛ).
- Рассмотрено обращение сложных распределений:
  - Показана некорректность прямого решения системы уравнений;
  - Найдена рекуррентная формула обращения;
  - Предложена оптимизированная вариация;
  - Предложена корректировка и решение через минимизацию;
  - Показана сходимость и смещение алгоритмов.
- Продолжено исследование радиобиологических данных:
  - Применено обращение к данным *in vivo* и *in vitro*;
  - Были параметризованы полученные вероятности;
  - Предложена интерпретация.